

Block-Zigzag Attention 的去重复复杂度、Block Trade-off 与有向 Expander 扩展

Qi 的研究备忘录

2026-06-09

摘要

这份备忘录修正前一版复杂度推导中的一个重要细节：标准 zig-zag product 每个 token 有 d^2 条由小图边标号 (a, b) 生成的路径/多重边，但如果实际实现只保留 boolean attention mask，则多个 (a, b) 可能落到同一个 key，或者落回本地 dense block，从而真实不同 key 数不超过 d^2 。因此跨块项应写成上界或写成带去重因子的精确式。设每个局部块大小为 $B = mn$ ，block 数为 q ，总 token 数 $T = qB$ ，跨块去重后平均远程邻居数为 $\bar{v} \leq d^2$ ，则一层 mask 相关复杂度为

$$\Theta(T(B + \bar{v})d_{\text{model}}) \leq \Theta(T(B + d^2)d_{\text{model}}).$$

在 B, d 固定且 q 增大时，相对全 attention 的理论节省确实随 q 增大；但这不是“block 越小越好”的无条件结论。原因是 B 同时影响 zig-zag 端口合法性、局部 inductive bias、多层混合深度和 GPU block-sparse kernel 的算术强度。本文进一步给出有向版本：把大图 G 改成入度/出度都为 B 的 directed expander，把小图 H 改成入度/出度都为 d 的 port digraph，用第二奇异值或 Eulerian directed Cheeger 理论控制混合；对应 directed block-zigzag attention 的复杂度仍为 $\Theta(T(B + \bar{v})d_{\text{model}})$ 。

目录

1 先给结论	2
2 符号和模型	3
3 精确的去重复复杂度	4
3.1 多重边计数	4
3.2 Boolean mask 计数	4
3.3 什么时候可以取等号	5
4 Attention FLOPs：理论边数不等于真实 wall-clock	5
5 和 full attention 的比较：哪些结论成立，哪些不成立	6
6 为什么不能无脑取 token-level：核心 trade-off	6
6.1 约束一：标准 zig-zag 中 B 不是自由 block size，而是大图端口数	6
6.2 约束二：局部 dense block 是表达力和归纳偏置，不只是成本项	7

1 先给结论	2
6.3 约束三：固定层数时，block 数越多，全局混合越难	7
6.4 约束四：GPU 上 block 太小会变成 irregular sparse	7
7 偏序：full、block、token-level 不是全序	8
8 有向 expander 的文献和定义	8
8.1 正则定向图与第二奇异值	8
8.2 Eulerian/non-regular 有向图	9
8.3 随机有向正则图	9
8.4 Ramanujan digraphs	10
9 Directed block-zigzag attention	10
9.1 构造	10
9.2 复杂度	10
9.3 有向谱保证	11
10 Causal / partial-order 版本：不能直接要求强连通 expander	11
10.1 Causal past-expander 的替代定义	11
10.2 三种可选有向结构	12
11 实验设计：怎样验证你的闭环	12
11.1 复杂度实验	12
11.2 图指标	12
11.3 模型消融	13
12 最终建议	13

1 先给结论

你截图中的两点判断是对的。

修正 1: qBd^2 是多重路径计数，不一定是 boolean mask 的不同 key 计数

给定一个 query token $x = (v, i)$, zig-zag 对每个 $(a, b) \in [d] \times [d]$ 生成一个目标 token。因此按路径标号计数必然是 d^2 。但若实际 attention mask 是 boolean mask, 重复目标会合并, 所以真实不同远程 key 数为

$$\nu(x) \leq d^2.$$

因此

$$E_{zz}^{\text{bool}} = \sum_x \nu(x) \leq Td^2.$$

只有在无重边、无自环、且不同 (a, b) 不碰撞时，才能把上界写成等号。

修正 2: local complete 与 zig-zag 的并集也应写成 $\leq$

由于 local block 已经包含同一 block 内的所有 key, 若某条 zig-zag 边最终回到同一 block, 则这条边对 boolean mask 没有新增 key。因此精确式应为

$$E_{\text{block}}^{\text{bool}} = T(B + \bar{v}), \quad 0 \leq \bar{v} \leq d^2,$$

而不是无条件等号

$$T(B + d^2).$$

后者是多重边实现、未去重实现, 或者无碰撞无重叠假设下的精确计数; 对 boolean mask, 它是上界。

关于 “ B, d 固定时 block 数越多越省”, 正确表述是: 相对于全 *attention*, 当 B, d 固定而总长度 $T = qB$ 增大时, *block-zigzag sparse attention* 的理论 *pair* 数从 T^2 降到 $\mathcal{O}(T)$, 所以相对加速比随 q 增大。这不等价于 “固定 T 时把 B 一直降到 1 最优”。固定 T 时, B 变小会降低局部 dense 成本, 但同时会损失局部 one-layer 表达、增加 block-level 全局混合所需层数, 并可能把硬件友好的 block-sparse GEMM 退化成低算术强度的 irregular sparse gather/scatter。

2 符号和模型

设每个局部 block 中有

$$B = mn$$

个 token, 共有 q 个 block, 总 token 数

$$T = qB.$$

把 token 写成二元组

$$x = (v, i), \quad v \in [q], \quad i \in [B].$$

其中 v 是 block/cloud 编号, i 是 block 内端口或 token 编号。local mask 是

$$\mathcal{N}_{\text{loc}}(v, i) = \{(v, j) : j \in [B]\},$$

所以每个 query 有 B 个 local key。如果包含 self attention, 这是 B ; 如果不含 self, 则是 $B - 1$, 量级不变。本文默认包含 self, 便于公式简洁。

标准 zig-zag product 的端口一致性要求大图 G 是 B -正则图, 小图 H 有 B 个顶点且是 d -正则图。用旋转映射记为

$$\text{Rot}_G(v, i') = (w, j'),$$

表示从 block v 的第 i' 个端口跳到 block w , 并在 w 端收到端口标签 j' 。一次 zig-zag 为

$$(v, i) \xrightarrow{H, a} (v, i') \xrightarrow{G} (w, j') \xrightarrow{H, b} (w, j).$$

其中 $a, b \in [d]$ 。

3 精确的去重复复杂度

3.1 多重边计数

定义 $\mathcal{M}_{zz}(x)$ 为从 x 出发、由所有 $(a, b) \in [d]^2$ 生成的多重目标 multiset。无论是否发生碰撞, multiset 的大小都是

$$|\mathcal{M}_{zz}(x)| = d^2.$$

因此多重边计数为

$$E_{zz}^{\text{multi}} = Td^2 = qBd^2.$$

如果实现方式是：对每个 query 显式枚举所有 (a, b) 并逐条算一次 attention score, 即使最后把同一 key 合并, 这个实现仍然付出 Td^2 个 score 的计算成本。

3.2 Boolean mask 计数

定义去重后的 zig-zag 目标集合

$$\mathcal{N}_{zz}(x) = \text{set}(\mathcal{M}_{zz}(x)).$$

定义真正新增的远程 key 数

$$\nu(x) = |\mathcal{N}_{zz}(x) \setminus \mathcal{N}_{\text{loc}}(x)|.$$

令平均新增远程 key 数

$$\bar{\nu} = \frac{1}{T} \sum_x \nu(x).$$

则 boolean mask 的精确 pair 数是

$$E_{\text{block}}^{\text{bool}} = \sum_x |\mathcal{N}_{\text{loc}}(x) \cup \mathcal{N}_{zz}(x)| = T(B + \bar{\nu}). \quad (1)$$

并且

$$E_{\text{block}}^{\text{bool}} \leq T(B + d^2). \quad (2)$$

更细地, 令

$$c(x) = d^2 - |\mathcal{N}_{zz}(x)|$$

表示不同 (a, b) 落到同一目标造成的重复损失; 令

$$r(x) = |\mathcal{N}_{zz}(x) \cap \mathcal{N}_{\text{loc}}(x)|$$

表示 zig-zag 回到本地 dense block 后被 local mask 吸收的损失。则

$$\nu(x) = d^2 - c(x) - r(x), \quad (3)$$

于是

$$E_{\text{block}}^{\text{bool}} = T(B + d^2) - \sum_x (c(x) + r(x)). \quad (4)$$

这就是你截图里标注的“如果有自环或路径最终回到同一 block, 就可能有重叠”的严格版本。

3.3 什么时候可以取等号

命题 3.1 (无碰撞、无本地重叠时的等号条件). 假设:

1. 大图 G 是 *simple*、*loopless*、 B -*regular*; 也就是说, 同一 *block* v 不会通过两个不同端口连到同一个 *block* w , 且没有 $v \rightarrow v$ 自环。
2. 小图 H 是 *simple*、*loopless*、 d -*regular*; 也就是说, 从任一端口出发的 d 个 H 邻居互不相同。
3. *local block* 与跨块边按 *boolean union* 合并。

则对每个 *token* x , *zig-zag* 生成的 d^2 个目标互不相同, 并且都不在 x 的本地 *block* 内。因此

$$\nu(x) = d^2, \quad E_{\text{block}}^{\text{bool}} = T(B + d^2).$$

证明. 固定 $x = (v, i)$ 。第一步 H 从 i 到 i'_a , 由于 H *simple*, i'_a 随 a 互不相同。第二步 G 从 (v, i'_a) 跳到 (w_a, j'_a) 。由于 G *simple* 且 *loopless*, 不同 i'_a 对应不同的目标 *block* $w_a \neq v$ 。第三步在每个 w_a 内由 H 从 j'_a 到 $j_{a,b}$; 对固定 a , 不同 b 给出不同 $j_{a,b}$ 。不同 a 的目标 *block* 已不同, 所以不会跨 a 碰撞。又因 $w_a \neq v$, 所有目标都在本地 *block* 外。□

备注 3.2. 经典 *expander* 和 *zig-zag* 文献常允许 *multigraph* 或 *edge label* 形式, 因为谱分析和旋转映射更自然。工程实现若用 *boolean mask*, 就必须把 (4) 中的碰撞项纳入实际 *edge count*; 否则 *FLOP* 估计偏保守。

4 Attention FLOPs: 理论边数不等于真实 wall-clock

只看 attention score 与 value mixing, mask pair 数为 E 时, 一层多头 attention 的主项可以写成

$$\Theta(Ed_{\text{model}}),$$

其中常数包括 $QK^\top$ 的 dot product、softmax normalization 和对 V 的加权求和。于是 boolean mask 的复杂度为

$$\boxed{\text{FLOPs}_{\text{attn,mask}} = \Theta(T(B + \bar{\nu})d_{\text{model}}) \leq \Theta(T(B + d^2)d_{\text{model}})}. \quad (5)$$

如果每个 head 单独存 attention score, score memory 为

$$\Theta(hT(B + \bar{\nu})).$$

完整 Transformer block 还包含 QKV/output projection 和 FFN:

$$\Theta(Td_{\text{model}}^2) + \Theta(T(B + \bar{\nu})d_{\text{model}}) + \Theta(Td_{\text{model}}d_{\text{ff}}). \quad (6)$$

所以“block 数越多越省”只直接作用在中间的 attention mask 项; 当 d_{model} 很大、 T 不够大或 kernel 不够高效时, 线性层和 memory movement 可能主导 wall-clock。

5 和 full attention 的比较：哪些结论成立，哪些不成立

全 attention 的有向 pair 数是

$$E_{\text{full}} = T^2 = q^2 B^2.$$

block-zigzag boolean mask 是

$$E_{\text{block}}^{\text{bool}} = T(B + \bar{\nu}).$$

因此 pair 级别的理论节省比为

$$\frac{E_{\text{full}}}{E_{\text{block}}^{\text{bool}}} = \frac{T}{B + \bar{\nu}} = \frac{qB}{B + \bar{\nu}} \geq \frac{qB}{B + d^2}. \quad (7)$$

如果 B, d 固定，且 $\bar{\nu} = \Theta(d^2)$ ，则这个 ratio 是 $\Theta(q)$ 。这说明：序列越长、block 越多，相对于 *full attention* 的理论节省越大。

但需要区分两个实验问题。

问题	正确结论	误区
固定 B, d ，增大 q ， 所以 $T = qB$ 也增大	sparse attention 绝对成本线性增大； full attention 成本二次增大；相对 full 的节省越来越大	不是说绝对时间会下降，而是增长斜 率从二次降到线性
固定 T ，改变 B ，于 是 $q = T/B$	FLOP 上界 $T(B + d^2)$ 随 B 变小而 下降，但质量、深度和硬件效率会变 差；通常存在 Pareto frontier	不能推出 $B = 1$ 一定最好，也不能 把 zig-zag product 直接取到 $B = 1$

6 为什么不能无脑取 token-level：核心 trade-off

6.1 约束一：标准 zig-zag 中 B 不是自由 block size，而是大图端口数

标准 zig-zag product 要求

$$|V(H)| = \deg(G) = B.$$

因此如果小图 H 的度数为 d ，至少需要

$$B \geq d + 1$$

才能有 simple d -regular 小图。若还要求大图 G 是 simple B -regular digraph/graph，那么 block 数 q 也必须足够大，通常要有 $q \geq B + 1$ 。因此 $B = 1$ 与固定 $d \geq 1$ 的 zig-zag product 并不兼容。

如果要做“一个 block 就一个 token”，那已经不是这个 block-zigzag product，而是直接在 T 个 token 上构造一个 D -regular expander attention mask：

$$E = TD.$$

这当然可以做，而且复杂度更低；但它失去了块内 dense attention，也失去了 block-sparse kernel 的规则矩阵块结构。

6.2 约束二：局部 dense block 是表达力和归纳偏置，不只是成本项

若 token 序列有自然局部性，例如文本邻近 token、图像邻近 patch 或多模态局部 patch， B 相当于 one-layer 完整局部交互窗口。把 B 缩小会让局部比较能力下降。为了补回来，通常需要额外 local window、卷积、线性 attention 或更多层。Longformer 和 BigBird 都把 local window 与 global/random 结构组合起来，而不是只保留随机远程边 [11, 10]。Expformer 在图 Transformer 中也不是只用 expander 边，而是组合原图边、expander 边和 virtual global nodes [12]。

6.3 约束三：固定层数时，block 数越多，全局混合越难

设 block-level directed/undirected expander 的归一化转移矩阵为 P ，均匀平均算子为 $J = \mathbf{1}\mathbf{1}^\top/q$ ，并满足

$$\|P - J\|_2 \leq \lambda < 1.$$

则 L 层线性平均后的 L_2 混合满足

$$\|P^L - J\|_2 \leq \lambda^L.$$

但从单个 block 出发的 total variation 距离有一个 $\sqrt{q}$ 因子：

$$\|P^L(v, \cdot) - \text{Unif}([q])\|_{\text{TV}} \leq \frac{1}{2}\sqrt{q}\lambda^L. \quad (8)$$

若要把这个量压到 ε ，需要大约

$$L \gtrsim \frac{\frac{1}{2}\log q + \log(1/\varepsilon)}{-\log \lambda}. \quad (9)$$

因此固定 T 时， B 越小， $q = T/B$ 越大，在固定层数下全局信息覆盖越难。若允许层数随 $\log q$ 增长，则整体成本应写成

$$\text{Cost}_{\text{global mix}} \approx T(B + d^2)d_{\text{model}} \cdot (L_0 + \alpha \log(T/B)), \quad (10)$$

这已经不是单调偏序，而是一个局部窗口、远程度数、层数和硬件效率之间的 Pareto trade-off。

6.4 约束四：GPU 上 block 太小会变成 irregular sparse

理论 FLOPs 少，不保证 wall-clock 快。FlashAttention 的核心提醒是 attention 性能受 HB-M/SRAM 间 IO 支配，算法必须 IO-aware；它也把 block-sparse 作为需要专门 kernel 支持的近似 attention 路线 [13]。2025 年的 Native Sparse Attention 进一步强调，长上下文 sparse attention 要把算法稀疏性与硬件对齐一起设计，才会在训练和推理中同时兑现加速 [14]。因此 B 太小可能降低矩阵块复用和 arithmetic intensity，导致实际时间不随理论 edge 数同比下降。

对实验的预测

若固定 B, d 并增大 q ，相对 full attention 的速度优势应越来越明显。若固定 T 并扫描 B ，理论 edge count 倾向于较小 B ，但 wall-clock 和精度大概率出现 U-shape 或 Pareto frontier：太大的 B 被局部 dense 的 TB 项拖慢，太小的 B 被 kernel overhead、弱局部性和更多层需求拖累。

7 偏序: full、block、token-level 不是全序

可以定义 mask 的一层表达偏序:

$$M_1 \preceq M_2 \iff \mathcal{E}(M_1) \subseteq \mathcal{E}(M_2).$$

在这个偏序下, full attention 是最大元素, 因为它包含所有 query-key pair。若 attention bias 可以把多余边权重压到 $-\infty$, 则 M_2 可以模拟 M_1 的一层通信; 反过来通常不行。

但是不同 B 的 block-zigzag mask 通常不可比: 一个 $B = 64$ 的 mask 有更强局部 one-layer dense 比较, 另一个 $B = 16$ 的 mask 有更多 block-level 远程混合机会。它们之间不是简单的包含关系。因此更合理的比较对象是多指标:

$$(\text{edge count}, B, \bar{\nu}, \sigma_2, L, \text{kernel efficiency}, \text{task loss}).$$

这也是为什么“存在某种条件或假设下结论成立”的正确形式是 Pareto/偏序, 而不是单一标量上的全序。

8 有向 expander 的文献和定义

Attention mask 本质上有向的: query x 选择 key y , 并不要求 y 同时选择 x 。因此有向版本比无向版本更贴近实现。

8.1 正则定向图与第二奇异值

定义 8.1 (regular directed spectral expander). 设 $\mathcal{D} = (V, E)$ 是 N 个点的 D -in/ D -out regular digraph。令 A 为有向邻接矩阵,

$$P = \frac{1}{D}A.$$

则 P 是 doubly stochastic, 均匀分布是平稳分布。定义

$$\sigma_2(P) = \|P - J\|_{2 \rightarrow 2}, \quad J = \frac{1}{N}\mathbf{1}\mathbf{1}^\top.$$

若 $\sigma_2(P) \leq \lambda < 1$, 则称 $\mathcal{D}$ 是 directed singular-value expander。

使用奇异值而不是只用特征值, 是因为有向邻接矩阵一般非正规; 特征值小不一定排除短期 transient amplification。Ramanujan digraph 文献也特别强调 non-normality 的问题, 并引入 almost-normal/ r -normal 条件来恢复随机游走控制 [6, 7]。

命题 8.2 (directed mixing lemma, singular-value 版本). 若 $\mathcal{D}$ 是 D -in/ D -out regular digraph, 且 $\sigma_2(P) \leq \lambda$, 则对任意 $S, T \subseteq V$, 有

$$\left| e(S, T) - \frac{D|S||T|}{N} \right| \leq D\lambda\sqrt{|S||T|}. \quad (11)$$

证明. 写 $e(S, T) = \mathbf{1}_S^\top A \mathbf{1}_T = D \mathbf{1}_S^\top P \mathbf{1}_T$ 。分解 $P = J + (P - J)$, 得到

$$\mathbf{1}_S^\top J \mathbf{1}_T = \frac{|S||T|}{N}.$$

剩余项由 Cauchy-Schwarz 和 $\|P - J\|_2 \leq \lambda$ 控制:

$$|\mathbf{1}_S^\top (P - J) \mathbf{1}_T| \leq \|\mathbf{1}_S\|_2 \|P - J\|_2 \|\mathbf{1}_T\|_2 \leq \lambda \sqrt{|S||T|}.$$

乘上 D 即得。 □

同理, 由 P doubly stochastic 可得

$$\|P^L - J\|_2 \leq \lambda^L, \quad (12)$$

以及从点质量出发的 total variation 控制

$$\|P^L(x, \cdot) - \text{Unif}(V)\|_{\text{TV}} \leq \frac{1}{2} \sqrt{N} \lambda^L.$$

这正是 directed expander 用于 bidirectional sparse attention 的核心理论。

8.2 Eulerian/non-regular 有向图

若 digraph 不是完全 regular, 但是 Eulerian 或近似 Eulerian, 即入度和出度可控, 则应使用 Markov chain 语言。令 P 为行随机矩阵, π 为平稳分布, $\Pi = \text{diag}(\pi)$ 。有向图的 conductance、Cheeger inequality 和 directed Laplacian 可以用 π 加权定义。Chung 给出了 directed graph Laplacian 和 Cheeger inequality, 用于非可逆 Markov chain 的收敛和比较问题 [3]; Chung-Kenter 进一步用随机游走和奇异值建立了 directed discrepancy 与等周不等式 [4]。较新的 Lau-Tung-Wang 用 reweighted eigenvalue 方法给出 directed graphs/hypergraphs 的 Cheeger inequalities, 并把 directed expansion 与 fastest mixing 联系起来 [5]。

对 attention 工程而言, Eulerian/近似 regular 的含义是: 每个 query 的 out-degree 固定或近似固定, 且每个 key 的 in-degree 不要过度集中。否则某些 key 会成为 hub, 破坏负载均衡和均匀通信。

8.3 随机有向正则图

最直接的工程构造是取 D 个随机置换 $\pi_1, \dots, \pi_D$, 加有向边

$$v \rightarrow \pi_a(v), \quad a \in [D].$$

这自动给出 D -in/ D -out regular directed multigraph。也可以从 uniform random D -regular digraph 中采样。随机正则图/有向图通常有强谱扩张性质; 例如 Zhu 对随机二部双正则图的第二特征值给出高概率界, 并推出 uniform random d -regular digraph 的第二奇异值为 $O(\sqrt{d})$ 的高概率结果 [8]。Coste 研究了带给定度序列的 sparse random digraph 的 transition matrix 第二特征值, 给出 sparse non-reversible Markov chain 的谱隙上界结果 [9]。

归一化后, 若第二奇异值 $s_2(A) = O(\sqrt{D})$, 则

$$\sigma_2(P) = O\left(\frac{1}{\sqrt{D}}\right),$$

这正是常数度 directed expander 所需的常数谱隙。

8.4 Ramanujan digraphs

Ramanujan digraphs 是有向图中的最优谱对象之一。Parzanchevski 的综述系统整理了 Ramanujan graphs 与 digraphs 的平行概念，特别强调 almost-normal Ramanujan digraphs 的小直径、采样 Chernoff bound、cover time 和 cutoff 等性质 [6]。Lubetzky–Lubotzky–Parzanchevski 证明，从 Ramanujan complexes 上 collision-free 的 k -regular branching operator 可得到 r -normal Ramanujan digraph，并推出随机游走在 $\log_k n$ 时间尺度上的 cutoff [7]。

对本文结构而言，Ramanujan digraph 是很强但不一定最工程友好的目标。更实用的目标通常是：

$$\sigma_2(P) \leq \lambda < 1,$$

并且邻接表可快速生成、入/出度负载均衡、block layout 对 GPU 友好。

9 Directed block-zigzag attention

9.1 构造

把大图 G 替换成 B -in/ B -out regular digraph，顶点为 block 集合 $[q]$ 。每个 block 的出边标号为 $[B]$ ，入边标号也为 $[B]$ 。定义有向旋转映射

$$\text{Rot}_G^+(v, i') = (w, j'),$$

表示从 v 的第 i' 条出边到达 w ，且该边在 w 的入端口标号为 j' 。由于入/出度都为 B ，这个映射是 $[q] \times [B]$ 到自身的一个置换。

令小图 H 是 $[B]$ 上的 d -in/ d -out regular port digraph。给定 $x = (v, i)$ 和 $(a, b) \in [d]^2$ ，定义

$$\begin{aligned} i' &\in N_H^+(i; a), \\ (w, j') &= \text{Rot}_G^+(v, i'), \\ j &\in N_H^+(j'; b), \\ x &\rightarrow (w, j). \end{aligned}$$

这就是 directed zig-zag attention 的远程边。

9.2 复杂度

多重边版本每个 token 仍有 d^2 条出边。Boolean mask 去重后，定义

$$\nu^+(x) = |\mathcal{N}_{\text{zz}}^+(x) \setminus \mathcal{N}_{\text{loc}}(x)|, \quad \bar{\nu}^+ = \frac{1}{T} \sum_x \nu^+(x).$$

则

$$E_{\text{dir block}}^{\text{bool}} = T(B + \bar{\nu}^+) \leq T(B + d^2). \quad (13)$$

所以

$$\text{FLOPs}_{\text{directed attn}} = \Theta(T(B + \bar{\nu}^+)d_{\text{model}}) \leq \Theta(T(B + d^2)d_{\text{model}}). \quad (14)$$

如果 G, H 都是 simple directed regular 且无 directed self-loop，并且 G 没有从 v 到同一 w 的多条平行出边，则同样有 $\bar{\nu}^+ = d^2$ 。若使用随机置换模型，平行边或自环可以保留为 multigraph，

也可以通过去重/重采样消除；保留 multigraph 时谱分析方便，boolean mask 时 edge count 会更低。

9.3 有向谱保证

令 P_H 是 port digraph 的转移矩阵，令 R_G 是 $\text{Rot}_G^\perp$ 对 $[q] \times [B]$ 的置换矩阵。Directed zig-zag 的转移矩阵可写成

$$P_{\text{dzz}} = (I_q \otimes P_H) R_G (I_q \otimes P_H). \quad (15)$$

该式与无向 RVW zig-zag 的“小图一步-大图一步-小图一步”完全对应。RVW 的原始 zig-zag product 证明说明，product 继承大图规模、小图度数和两者的扩张性 [2]；在 directed setting 中，最稳妥的做法是用 σ_2 而非非正规特征值来验证

$$\sigma_2(P_{\text{dzz}}) \leq \lambda_{\text{dzz}} < 1.$$

一旦这个不等式成立，(11)–(12) 的 directed mixing 结论立即适用。

实际工程可以采用两条路线：

1. **构造即相信**：选用随机 regular digraph 或已知 directed/Ramanujan digraph 族，依赖高概率或显式理论。
2. **构造后数值证书**：对给定 mask 的 sparse transition matrix 用 power iteration/Lanczos 估计 $\sigma_2(P - J)$ ；这比精确验证组合 directed expansion 便宜得多。

10 Causal / partial-order 版本：不能直接要求强连通 expander

如果用于 encoder 或 bidirectional attention，有向 expander 可以强连通并快速混合。但如果用于 autoregressive causal attention，必须满足

$$\text{query at time } t \text{ can only attend to keys } s \leq t.$$

这会把 mask 变成 DAG 或近似 DAG。DAG 不可能是强连通 expander；所以不能把普通 directed expander 结论原封不动套到 causal mask 上。

10.1 Causal past-expander 的替代定义

对 causal setting，更合适的目标不是 stationary mixing，而是“向过去的低延迟覆盖”。可以在 block 时间轴 $1, \dots, q$ 上定义：每个 block t 连向 D 个过去 block

$$\Gamma^-(t) \subseteq \{1, \dots, t\}, \quad |\Gamma^-(t)| = D.$$

希望满足：对任意 t 和窗口/前缀 $S \subseteq [1, t]$ ，从 t 经过 L 层反向可达的 past set 快速增大。一个可实现构造是

$$\Gamma^-(t) = \{t - 2^r : 0 \leq r < R\} \cup \text{若干随机过去 block},$$

再加 local window。这样任意过去距离可在 $O(\log q)$ 层内通过二进制跳转覆盖，随机过去边减少固定 skip pattern 的盲区。

这类 causal graph 的复杂度仍是

$$\Theta(T(B + D)d_{\text{model}}),$$

但理论指标应是 reachability/latency/prefix coverage, 而不是 $\sigma_2(P)$ 的 stationary mixing。

10.2 三种可选有向结构

结构	适用场景	理论指标	复杂度
Bidirectional directed expander	encoder、图 Transformer、非因果长上下文	$\sigma_2(P)$ 、directed mixing、directed discrepancy	$T(B + D)$
Directed zigzag	需要 port/block 结构和显式邻居 oracle	$\sigma_2(P_{\text{dzz}})$ 或继承式谱界；去重后 $\bar{\nu} \leq d^2$	$T(B + \bar{\nu})$
Causal expander / skip DAG	autoregressive LM	过去覆盖半径、prefix expansion、最大入度负载	$T(B + D)$

11 实验设计：怎样验证你的闭环

11.1 复杂度实验

建议分两组做，否则容易把“相对 full 的节省”和“固定 T 的最优 B ”混在一起。

实验 A：固定 B, d , 增大 q 。 例如固定 $B = 32, d = 4$, 令 $q \in \{64, 128, 256, 512, 1024\}$ 。比较：

$$\frac{\text{full attention time}}{\text{block-zigzag time}}, \quad \frac{T^2}{T(B + \bar{\nu})}.$$

预期：理论 ratio 近似线性增长；实际 wall-clock ratio 增长但会受 kernel、memory bandwidth 和 batch size 影响。

实验 B：固定 T , 扫描 B 。 例如固定 $T = 65536$, 扫

$$B \in \{8, 16, 32, 64, 128, 256\},$$

并保持 d 、层数 L 或总远程预算可控。记录：

$$E_{\text{bool}}, \quad \bar{\nu}/d^2, \sigma_2, \text{wall-clock, validation loss/perplexity}.$$

预期：edge count 偏向小 B ；wall-clock 和质量不一定单调，可能出现最优中间 block size。

11.2 图指标

每个 mask 实例都建议输出：

1. 去重率： $\bar{\nu}/d^2$ 。
2. 本地重叠率： $\frac{1}{Td^2} \sum_x r(x)$ 。
3. 最大入度和入度方差：检测 hub。
4. directed singular gap：估计 $\sigma_2(P - J)$ 。
5. 多层覆盖： L 层后每个点可达的不同 block/token 数。

11.3 模型消融

至少比较五种 mask:

1. full attention;
2. local dense only;
3. token-level directed random expander;
4. block local dense + random directed expander;
5. block local dense + directed zig-zag.

如果任务是 causal LM, 还要加入 causal local window、causal skip DAG 和 causal random-past edges。

12 最终建议

1. 以后文档中把

$$qB^2 + qBd^2$$

写成“多重边/无碰撞上界”, boolean mask 的主公式改成

$$T(B + \bar{\nu}), \quad \bar{\nu} \leq d^2.$$

2. 对“block 数越多越省”的表述改成: 固定 B, d 、增大总长度 $T = qB$ 时, 相对 full attention 的节省随 q 增大; 固定 T 时 B 是 trade-off 参数。
3. 如果想做最干净的理论闭环, 建议先做 bidirectional directed singular expander 版本, 因为 attention 本来是有向, 且 σ_2 给出直接的 mixing lemma。
4. 如果目标是自回归模型, 不要声称 causal mask 是普通 directed expander; 应改用 causal past-expander、skip DAG 或 prefix expansion 指标。
5. 工程上优先扫 $B \in \{16, 32, 64, 128\}$, 因为这些 block size 更接近 GPU block-sparse kernel 的有效区间; $B = 1$ 应作为 token-level expander baseline, 而不是 block-zigzag 的极限。

参考文献

- [1] Shlomo Hoory, Nathan Linial, and Avi Wigderson. Expander graphs and their applications. *Bulletin of the American Mathematical Society*, 43(4):439–561, 2006.
- [2] Omer Reingold, Salil Vadhan, and Avi Wigderson. Entropy waves, the zig-zag graph product, and new constant-degree expanders. *Annals of Mathematics*, 155(1):157–187, 2002.
- [3] Fan Chung. Laplacians and the Cheeger inequality for directed graphs. *Annals of Combinatorics*, 9(1):1–19, 2005.
- [4] Fan Chung and Franklin Kenter. Discrepancy inequalities for directed graphs. *Discrete Applied Mathematics*, 176:30–42, 2014.

- [5] Lap Chi Lau, Kam Chuen Tung, and Robert Wang. Cheeger inequalities for directed graphs and hypergraphs using reweighted eigenvalues. arXiv:2211.09776, 2022.
- [6] Ori Parzanchevski. Ramanujan graphs and digraphs. arXiv:1804.08028, 2018.
- [7] Eyal Lubetzky, Alexander Lubotzky, and Ori Parzanchevski. Random walks on Ramanujan complexes and digraphs. *Journal of the European Mathematical Society*, 22(11):3441–3466, 2020.
- [8] Yizhe Zhu. On the second eigenvalue of random bipartite biregular graphs. arXiv:2005.08103, 2020; journal version in *Journal of Theoretical Probability*, 2023.
- [9] Simon Coste. The spectral gap of sparse random digraphs. arXiv preprint, 2017; journal version in *Annales de l’Institut Henri Poincaré, Probabilités et Statistiques*, 57(2), 2021.
- [10] Manzil Zaheer et al. Big Bird: Transformers for longer sequences. *Advances in Neural Information Processing Systems*, 33, 2020.
- [11] Iz Beltagy, Matthew E. Peters, and Arman Cohan. Longformer: The long-document Transformer. arXiv:2004.05150, 2020.
- [12] Hamed Shirzad, Ameya Velingker, Balaji Venkatachalam, Danica J. Sutherland, and Ali Kemal Sinop. Exphormer: Sparse Transformers for graphs. *International Conference on Machine Learning*, 2023.
- [13] Tri Dao, Daniel Y. Fu, Stefano Ermon, Atri Rudra, and Christopher Re. FlashAttention: Fast and memory-efficient exact attention with IO-awareness. arXiv:2205.14135, 2022.
- [14] Jingyang Yuan et al. Native Sparse Attention: Hardware-aligned and natively trainable sparse attention. arXiv:2502.11089, 2025.
- [15] Bailin Wang, Chang Lan, Chong Wang, and Ruoming Pang. RATTENTION: Towards the minimal sliding window size in local-global attention models. arXiv:2506.15545, 2025.