

有向 Block-Zigzag Attention 的扩张性、Boolean 去重漏洞与完整修正版

Qi 的研究备忘录

2026-06-10

摘要

本文补上 block-zigzag attention 复杂度和有向 zig-zag 扩张性证明中的关键漏洞。结论分三层：第一，带端口标号的 directed zig-zag product，或保留 multiplicity 的带权版本，可以继承 singular-value expansion；若大图 G 的第二奇异值为 λ_G ，小端口图 H 的第二奇异值为 μ_H ，则

$$\|P_{zz} - J\|_2 \leq \sqrt{\lambda_G^2 + 2\mu_H^2 - \lambda_G^2\mu_H^2} \leq \sqrt{\lambda_G^2 + 2\mu_H^2}.$$

因此当 $\lambda_G^2 + 2\mu_H^2 < 1$ 时，labelled directed zig-zag 是有向 singular-value expander。第二，如果实现中只保留 boolean attention mask，那么重复 (a, b) 路径会被合并，真实远程不同 key 数是 $\nu(x) \leq d^2$ ，并且 row degree、column degree 都可能不均匀；此时不能无条件把 labelled zig-zag 的谱扩张性转移过去。第三，对 attention 实现，最稳的闭环是：计算上 unique key 去重，数学上保留 multiplicity weight，例如对重复目标加入 $\log C_{xy}$ attention bias；或者在 boolean support 上做 in/out degree repair，再验证 directed singular value。复杂度上，若每个局部块大小为 $B = mn$ ，block 数为 q ，总 token 数 $T = qB$ ，则

$$E_{\text{block}}^{\text{bool}} = T(B + \bar{\nu}), \quad 0 \leq \bar{\nu} \leq d^2,$$

所以 $T(B + d^2)$ 是上界或无碰撞情形下的等号，而不是一般 boolean mask 的精确式。

目录

1 一页结论	1
2 Block-zigzag attention 的精确计数	3
3 为什么“block 数越多越省”不是单调全序	4
3.1 端口合法性约束	4
3.2 扩张质量约束	5
3.3 硬件和表达 trade-off	5
4 有向 singular-value expander 定义	5
5 Labelled directed zig-zag product	6
5.1 大图、小图与旋转映射	6
5.2 继承扩张性定理	7

1 一页结论	2
6 Boolean 去重为什么破坏证明	9
6.1 Multiplicity matrix 与 boolean support	9
6.2 去重后原证明的断点	10
7 Boolean 去重后可以保留理论的充分条件	10
7.1 条件一：无碰撞	10
7.2 条件二：计算去重，但保留 multiplicity weight	11
7.3 条件三：degree repair 后做 perturbation certificate	11
7.4 条件四：非正则 boolean mask 的正确证书	12
8 Local complete block 与 remote zig-zag 的带权理论模型	12
9 有向扩展：Eulerian、非正则与 causal 情形	13
9.1 Eulerian directed expander	13
9.2 Causal/partial-order mask 不能是强连通 expander	13
10 实验和实现 checklist	14
10.1 复杂度闭环：固定 B, d ，增加 q	14
10.2 Trade-off 闭环：固定 T ，扫描 B	14
10.3 Boolean 去重诊断	14
10.4 三种实现对比	15
11 最终可引用的修正版表述	15
12 参考文献	16

1 一页结论

你指出的两个问题都是真问题。正确版本如下。

结论 A: 有向 zig-zag 的继承扩张性成立, 但对象必须是 labelled/multigraph/weighted 版本

设大图 G 是 B -in/ B -out regular directed graph, 并且有双射旋转映射

$$\text{Rot}_G : [q] \times [B] \rightarrow [q] \times [B].$$

设小图 H 是 d -in/ d -out regular directed graph, 转移矩阵为 P_H 。令

$$\lambda_G = \|P_G - J_q\|_2, \quad \mu_H = \|P_H - J_B\|_2,$$

其中 P_G 是由 Rot_G 诱导的 block-level doubly stochastic 转移矩阵, $J_n = n^{-1}\mathbf{1}\mathbf{1}^\top$ 。带端口标号的 directed zig-zag 转移矩阵满足

$$\|P_{zz} - J_{qB}\|_2 \leq \sqrt{\lambda_G^2 + 2\mu_H^2 - \lambda_G^2\mu_H^2} \leq \sqrt{\lambda_G^2 + 2\mu_H^2}.$$

所以只要 $\lambda_G^2 + 2\mu_H^2 < 1$, 就得到 directed singular-value expander。

结论 B: boolean 去重后不能自动继承

对一个 query token x , labelled zig-zag 有 d^2 条由 $(a, b) \in [d]^2$ 标号的路径。令

$$C_{xy} = \#\{(a, b) : \text{zz}(x, a, b) = y\}.$$

labelled 转移矩阵是

$$P_{xy} = \frac{C_{xy}}{d^2}.$$

它是 doubly stochastic。boolean 去重后只保留

$$A_{xy}^{\text{bool}} = \mathbf{1}_{\{C_{xy} > 0\}}, \quad Q_{xy} = \frac{A_{xy}^{\text{bool}}}{r_x}, \quad r_x = \sum_y A_{xy}^{\text{bool}}.$$

此时 Q 只是 row-stochastic。一般有

$$r_x < d^2, \quad \mathbf{1}^\top Q \neq \mathbf{1}^\top,$$

所以 Q 通常不是 doubly stochastic, 均匀分布不再是 stationary distribution, 不能直接写 $\|Q - J\|_2 < 1$ 来证明向均匀平均混合。

结论 C: attention 实现建议

有三个可证明路线:

1. **不去 multiplicity**: 保留重复边, 或者 unique key 后加入 $\log C_{xy}$ bias。这样数学上等价于 labelled multigraph, 扩张性继承定理直接适用。
2. **证明无碰撞**: 若所有 $C_{xy} \in \{0, 1\}$, 则 boolean mask 与 labelled graph 相同, 扩张性直接继承。
3. **degree repair + 谱证书**: 去重后把 boolean support 修补成 r -in/ r -out regular digraph, 并验证

$$\|Q - P_{zz}\|_2 \leq \delta, \quad \rho_{zz} + \delta < 1.$$

其中 $\rho_{zz} = \|P_{zz} - J\|_2$ 。这时 Q 仍是 directed singular-value expander。

2 Block-zigzag attention 的精确计数

每个 token 写成

$$x = (v, i), \quad v \in [q], \quad i \in [B],$$

其中 $B = mn$ 是 block 内 token 数, q 是 block 数, 总 token 数为

$$T = qB.$$

局部完全图 mask 为

$$\mathcal{N}_{\text{loc}}(v, i) = \{(v, j) : j \in [B]\},$$

因此每个 query 有 B 个 local key。若不允许 self attention, 把 B 换成 $B - 1$ 即可, 不影响量级。

小端口图 H 是 $[B]$ 上的 d -out regular directed graph。给定边标号 $a, b \in [d]$, 一次 zig-zag 是

$$(v, i) \xrightarrow{H, a} (v, i') \xrightarrow{G} (w, j') \xrightarrow{H, b} (w, j).$$

所以 labelled remote path 数为

$$d^2.$$

但 boolean mask 的远程不同 key 数为

$$\nu(v, i) = |\{(w, j) : \exists (a, b) \in [d]^2, \text{zz}((v, i), a, b) = (w, j)\}| \leq d^2.$$

定义平均远程不同 key 数

$$\bar{\nu} = \frac{1}{T} \sum_{v, i} \nu(v, i).$$

则 remote boolean 边数为

$$E_{zz}^{\text{bool}} = T\bar{\nu} \leq Td^2.$$

如果再与 local complete block 取 union, 还要扣掉落回本地 block 的 remote 边。令

$$o(v, i) = |\mathcal{N}_{\text{loc}}(v, i) \cap \mathcal{N}_{zz}^{\text{bool}}(v, i)|.$$

则精确的 boolean key 数是

$$E_{\text{block}}^{\text{bool}} = \sum_{v,i} (B + \nu(v,i) - o(v,i)).$$

因此

$$E_{\text{block}}^{\text{bool}} = T(B + \bar{\nu} - \bar{o}) \leq T(B + d^2),$$

其中

$$\bar{o} = \frac{1}{T} \sum_{v,i} o(v,i).$$

若 zig-zag remote 边被设计成不落回本地, 且没有 (a,b) 碰撞, 则 $\bar{\nu} = d^2, \bar{o} = 0$, 这时才有等号

$$E_{\text{block}} = T(B + d^2).$$

若每个 attention score/value 聚合的主项按 d_{model} 计, 则 mask 相关 FLOPs 为

$$\text{FLOPs}_{\text{mask}}^{\text{bool}} = \Theta(T(B + \bar{\nu} - \bar{o})d_{\text{model}}) \leq \Theta(T(B + d^2)d_{\text{model}}).$$

这不包含 Q/K/V projection 和 FFN, 它们通常是 $\Theta(Td_{\text{model}}^2)$ 或 $\Theta(Td_{\text{model}}d_{\text{ff}})$, 与 mask 的 pair 数无关。

3 为什么 “block 数越多越省” 不是单调全序

full attention 的 pair 数是

$$E_{\text{full}} = T^2.$$

在 B, d 固定、 $T = qB \rightarrow \infty$ 时, block-zigzag 的上界为

$$E_{\text{block}} \leq T(B + d^2),$$

所以相对 full attention 的 pair ratio 满足

$$\frac{E_{\text{block}}}{E_{\text{full}}} \leq \frac{B + d^2}{T} = \frac{B + d^2}{qB} \xrightarrow{q \rightarrow \infty} 0.$$

这就是 “长上下文越长, 相对 full attention 越省” 的正确数学含义。

但是固定 T 时, 不能推出 $B = 1$ 最优。原因有三点。

3.1 端口合法性约束

标准 zig-zag 需要大图 G 的 degree 等于 block 内端口数 B 。若 $B = 1$, 则 G 是 1-in/1-out directed graph, 即一个 permutation digraph。其转移矩阵是 permutation matrix。在 $\mathbf{1}^\perp$ 上 permutation 不收缩, 所以

$$\lambda_G = \|P_G - J_q\|_2 = 1$$

除非 $q = 1$ 。于是它没有常数谱间隙, 不能作为 directed expander。

同时, 小图 H 有 B 个端口并且 d -regular, 至少需要

$$d \leq B$$

若要求简单无自环 digraph, 则通常还要

$$d \leq B - 1.$$

所以 $B = 1$ 也放不下有用的小端口 expander。

3.2 扩张质量约束

带端口的 directed zig-zag 要满足

$$\lambda_G^2 + 2\mu_H^2 < 1.$$

这里 λ_G 和 μ_H 不是免费参数, 而是由 B, d 和构造方式决定。小 B 会限制 H 的度数和混合能力, 也会限制 G 的端口随机性。固定 T 时, 理论 pair 成本

$$T(B + d^2)$$

只描述计算预算; 真正可行的配置还要满足

$$(B, d) \in \mathcal{F}_{\text{exp}} := \{(B, d) : d \leq B, \lambda_G(B)^2 + 2\mu_H(B, d)^2 < 1\}.$$

因此优化问题应写成

$$\min_{(B, d) \in \mathcal{F}_{\text{exp}} \cap \mathcal{F}_{\text{kernel}} \cap \mathcal{F}_{\text{task}}} T(B + d^2),$$

而不是无约束地令 $B \rightarrow 1$ 。

3.3 硬件和表达 trade-off

小 B 会降低局部 dense 项, 但也会带来三类损失。

- **表达损失:** 一个 block 内的 complete attention 提供强 local mixing。 B 太小, local inductive bias 消失。
- **层数损失:** remote expander 负责全局混合。若 λ_G, μ_H 变差, 需要更多层才能达到同样通信半径。
- **kernel 损失:** block-sparse attention 的 wall-clock 优势依赖块内 dense GEMM。 B 太小会退化为 irregular gather/scatter, 理论 FLOPs 低但 GPU 利用率差。

所以应期待一个 Pareto frontier, 而不是“block 越多越好”的单调规律。实验上应同时画出 perplexity/loss、tokens/sec、显存、 σ_2 、collision rate 和 degree imbalance。

4 有向 singular-value expander 定义

无向正则图可以直接用第二特征值。对有向图, 邻接矩阵一般不 normal, 特征值可能误导混合。因此本文用第二奇异值。

定义 4.1 (doubly stochastic directed singular-value expander). 设 $P \in \mathbb{R}^{N \times N}$ 是 *doubly stochastic Markov matrix*, 即

$$P\mathbf{1} = \mathbf{1}, \quad \mathbf{1}^\top P = \mathbf{1}^\top.$$

令

$$J_N = \frac{1}{N} \mathbf{1} \mathbf{1}^\top.$$

称 P 的 *directed singular expansion parameter* 为

$$\sigma(P) = \|P - J_N\|_2.$$

若一族 P_N 满足 $\sigma(P_N) \leq \rho < 1$, 则称其为 *doubly stochastic directed singular-value expander family*.

这个定义的好处是: 对任意均值为零的特征向量 $f \perp \mathbf{1}$, 有

$$\|Pf\|_2 \leq \sigma(P) \|f\|_2.$$

若 P 也是 doubly stochastic, 则

$$\|P^L - J_N\|_2 \leq \sigma(P)^L.$$

这给出多层 sparse attention 近似全局平均的线性化解释。

若 Q 只是 row-stochastic, 正确对象不再是 J_N , 而是 stationary distribution π :

$$\pi^\top Q = \pi^\top, \quad \pi^\top \mathbf{1} = 1.$$

在这种情况下应使用

$$\sigma_\pi(Q) = \left\| D_\pi^{1/2} (Q - \mathbf{1} \pi^\top) D_\pi^{-1/2} \right\|_2, \quad D_\pi = \text{diag}(\pi).$$

这才是 directed non-reversible Markov chain 的 $L_2(\pi)$ contraction 指标。若 π 明显偏离均匀分布, 则该 mask 即使混合很快, 也是在向非均匀权重混合; 这和每个 token 拥有相近通信带宽的目标不同。

5 Labelled directed zig-zag product

5.1 大图、小图与旋转映射

设大图 G 有 q 个 block/cloud, 每个 cloud 有 B 个出端口和 B 个入端口。端口旋转映射为一个双射

$$\text{Rot}_G : [q] \times [B] \rightarrow [q] \times [B].$$

若

$$\text{Rot}_G(v, i) = (w, j),$$

则表示从 cloud v 的出端口 i 跳到 cloud w 的入端口 j 。双射性等价于 labelled edge level 的入出端口完全匹配。令 R_G 是对应 permutation matrix。它是正交矩阵, 并且 doubly stochastic。

小图 H 是 $[B]$ 上的 d -in/ d -out directed graph。设其 row-stochastic 转移矩阵为

$$P_H = \frac{1}{d} A_H.$$

因为 H 入度和出度都为 d ，所以 P_H doubly stochastic。令

$$\mu_H = \|P_H - J_B\|_2.$$

定义

$$K = I_q \otimes P_H.$$

则 labelled zig-zag 的转移矩阵是

$$\boxed{P_{zz} = K R_G K.}$$

为了定义大图 block-level 转移，令

$$U : \mathbb{R}^q \rightarrow \mathbb{R}^{qB}, \quad (Ug)_{(v,i)} = B^{-1/2} g_v.$$

U 把 cloud-level 向量等距嵌入到 block 内常数子空间。定义

$$P_G := U^\top R_G U.$$

它的元素为

$$(P_G)_{vw} = \frac{1}{B} \#\{i \in [B] : \text{Rot}_G(v, i) = (w, j) \text{ for some } j\},$$

差一个转置约定不影响奇异值。 P_G 是 doubly stochastic。令

$$\lambda_G = \|P_G - J_q\|_2.$$

5.2 继承扩张性定理

定理 5.1 (directed labelled zig-zag 的 second singular value bound). 在上述假设下, $P_{zz} = K R_G K$ 是 doubly stochastic, 并且

$$\boxed{\|P_{zz} - J_{qB}\|_2 \leq \sqrt{\lambda_G^2 + 2\mu_H^2} - \lambda_G \mu_H \leq \sqrt{\lambda_G^2 + 2\mu_H^2}.}$$

因此若

$$\lambda_G^2 + 2\mu_H^2 < 1,$$

则 P_{zz} 是 directed singular-value expander。

证明. 由于 P_H 、 R_G 都 doubly stochastic, $K = I_q \otimes P_H$ 也 doubly stochastic, 因此 $P_{zz} = K R_G K$ doubly stochastic。

记

$$\Pi = I_q \otimes J_B.$$

Π 是对每个 cloud 内部取平均的正交投影。任取 $f \perp \mathbf{1}_{qB}$, 分解为

$$f = x + y, \quad x = \Pi f, \quad y = (I - \Pi)f.$$

于是 $x \perp y$, x 是 block 内常数部分, y 是 block 内零均值部分。

先看 x 。因为 $Kx = x$, 有

$$P_{zz}x = KR_Gx.$$

把 R_Gx 再分解为

$$R_Gx = \Pi R_Gx + (I - \Pi)R_Gx.$$

ΠR_Gx 的 cloud-level 作用正是 P_G 在 $\mathbf{1}_q^\perp$ 上的作用, 所以

$$\|\Pi R_Gx\|_2 \leq \lambda_G \|x\|_2.$$

又因为 R_G 是 permutation matrix,

$$\|R_Gx\|_2 = \|x\|_2.$$

因此

$$\|(I - \Pi)R_Gx\|_2^2 = \|x\|_2^2 - \|\Pi R_Gx\|_2^2.$$

K 在 block 内常数子空间上保持不变, 在每个 block 的零均值子空间上由 $P_H - J_B$ 控制, 因此

$$\|K(I - \Pi)z\|_2 \leq \mu_H \|(I - \Pi)z\|_2.$$

并且 $K\Pi z$ 与 $K(I - \Pi)z$ 仍然正交。于是

$$\begin{aligned} \|P_{zz}x\|_2^2 &= \|K\Pi R_Gx\|_2^2 + \|K(I - \Pi)R_Gx\|_2^2 \\ &\leq \|\Pi R_Gx\|_2^2 + \mu_H^2 \|(I - \Pi)R_Gx\|_2^2 \\ &= \mu_H^2 \|x\|_2^2 + (1 - \mu_H^2) \|\Pi R_Gx\|_2^2 \\ &\leq (\mu_H^2 + (1 - \mu_H^2)\lambda_G^2) \|x\|_2^2. \end{aligned}$$

令

$$a^2 = \mu_H^2 + (1 - \mu_H^2)\lambda_G^2 = \lambda_G^2 + \mu_H^2 - \lambda_G^2\mu_H^2.$$

则

$$\|P_{zz}x\|_2 \leq a \|x\|_2.$$

再看 y 。因为 y 在每个 cloud 内零均值,

$$\|Ky\|_2 \leq \mu_H \|y\|_2.$$

R_G 是 isometry, K 作为 doubly stochastic matrix 是 permutation matrices 的凸组合, 故 $\|K\|_2 \leq 1$ 。因此

$$\|P_{zz}y\|_2 = \|KR_GKy\|_2 \leq \mu_H \|y\|_2.$$

于是由三角不等式和 Cauchy-Schwarz,

$$\begin{aligned} \|P_{zz}f\|_2 &\leq a \|x\|_2 + \mu_H \|y\|_2 \\ &\leq \sqrt{a^2 + \mu_H^2} \sqrt{\|x\|_2^2 + \|y\|_2^2} \\ &= \sqrt{\lambda_G^2 + 2\mu_H^2 - \lambda_G^2\mu_H^2} \|f\|_2. \end{aligned}$$

由于 P_{zz} doubly stochastic, $\|P_{zz} - J\|_2$ 等于其在 $\mathbf{1}^\perp$ 上的 operator norm, 因此结论成立。 $\square$

备注 5.2. 这个证明没有使用无向性, 也没有使用矩阵 *normality*。关键条件只有三个: P_H doubly stochastic, R_G 是 permutation, 扩张参数用 *singular value* 而不是 *eigenvalue*。若只用有向矩阵的普通特征值, 非正规矩阵可能出现伪谱放大, 不能直接控制 L_2 mixing。

6 Boolean 去重为什么破坏证明

6.1 Multiplicity matrix 与 boolean support

对每个起点 $x = (v, i)$ 和终点 $y = (w, j)$, 定义 multiplicity

$$C_{xy} = \#\{(a, b) \in [d]^2 : \text{zz}(x, a, b) = y\}.$$

labelled/multigraph 版本的转移矩阵是

$$P_{xy} = \frac{C_{xy}}{d^2}.$$

因为每个起点有 d^2 条 labelled paths, 每个终点也有 d^2 条 labelled preimages, 所以

$$\sum_y C_{xy} = d^2, \quad \sum_x C_{xy} = d^2.$$

因此 $P = C/d^2$ doubly stochastic。

boolean 去重后, 矩阵变成

$$A_{xy} = \mathbf{1}_{\{C_{xy} > 0\}}.$$

出度和入度分别为

$$r_x = \sum_y A_{xy}, \quad c_y = \sum_x A_{xy}.$$

row-normalized boolean transition 是

$$Q_{xy} = \frac{A_{xy}}{r_x}.$$

它满足

$$Q\mathbf{1} = \mathbf{1},$$

但一般不满足

$$\mathbf{1}^\top Q = \mathbf{1}^\top.$$

所以均匀分布通常不是 stationary distribution。

例 6.1 (doubly stochastic multigraph 的 boolean support 未必 doubly stochastic). 考虑 *multiplicity matrix*

$$C = \begin{pmatrix} 2 & 1 & 0 \\ 1 & 1 & 1 \\ 0 & 1 & 2 \end{pmatrix}.$$

每行每列和都是 3, 所以 $P = C/3$ doubly stochastic。但 boolean support 为

$$A = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 1 & 1 \\ 0 & 1 & 1 \end{pmatrix}, \quad r = (2, 3, 2).$$

row-normalized 后

$$Q = \begin{pmatrix} 1/2 & 1/2 & 0 \\ 1/3 & 1/3 & 1/3 \\ 0 & 1/2 & 1/2 \end{pmatrix}.$$

它的 column sums 是

$$\left(\frac{5}{6}, \frac{4}{3}, \frac{5}{6}\right),$$

不是 $(1, 1, 1)$ 。所以从 *labelled multiplicity* 到 *boolean support* 的操作会破坏 *doubly stochastic* 性。

这个例子说明, “labelled zig-zag 是 regular” 并不能推出 “boolean 去重后仍 regular”。在真实 zig-zag 中, 若不同 (a, b) 频繁落到同一个 key, 也会出现同样问题。

6.2 去重后原证明的断点

labelled 证明需要

$$P_{zz}\mathbf{1} = \mathbf{1}, \quad \mathbf{1}^\top P_{zz} = \mathbf{1}^\top,$$

从而 J 是左右不变投影, 并且

$$P_{zz} - J$$

就是 $\mathbf{1}^\perp$ 上的收缩算子。boolean row-normalized Q 只有

$$Q\mathbf{1} = \mathbf{1}.$$

若

$$\mathbf{1}^\top Q \neq \mathbf{1}^\top,$$

则

$$JQ \neq J,$$

且

$$Q^L - J \neq (Q - J)^L.$$

因此就算某一层 $\|Q - J\|_2$ 数值不大, 也不能把它当作向均匀平均混合的谱证明。正确极限对象是

$$\mathbf{1}\pi^\top,$$

其中 π 是 Q 的 stationary distribution。

7 Boolean 去重后可以保留理论的充分条件

7.1 条件一: 无碰撞

命题 7.1 (collision-free boolean mask). 若对所有 x, y 都有

$$C_{xy} \in \{0, 1\},$$

即每个 query 的映射

$$[d] \times [d] \rightarrow [q] \times [B], \quad (a, b) \mapsto \text{zz}(x, a, b)$$

是 *injective*, 则 *boolean support* 满足

$$A = C, \quad r_x = c_x = d^2,$$

且 *row-normalized boolean transition* $Q = A/d^2$ 等于 *labelled transition* P_{zz} 。因此 *directed zig-zag* 的 *singular-value expansion* 完全继承。

证明. $C_{xy} \in \{0, 1\}$ 时, $A_{xy} = C_{xy}$ 。labelled matrix C 每行每列和都是 d^2 , 所以 A 也是 d^2 -in/ d^2 -out regular。于是 $Q = A/d^2 = C/d^2 = P_{zz}$ 。□

这个条件最干净, 但较强。实际实现中, 除非专门设计端口图和旋转映射, 否则不能默认成立。

7.2 条件二: 计算去重, 但保留 multiplicity weight

这是最推荐的理论-工程闭环。即使计算上只保留 unique key, 也不要丢 multiplicity。对每条 unique pair (x, y) 存储

$$C_{xy} \geq 1.$$

在 attention logits 中加入

$$\log C_{xy}.$$

若原始 content score 为

$$s_{xy} = \frac{q_x^\top k_y}{\sqrt{d_k}},$$

则使用

$$\tilde{s}_{xy} = s_{xy} + \log C_{xy}.$$

于是

$$\exp(\tilde{s}_{xy}) = C_{xy} \exp(s_{xy}).$$

这与真的把同一个 key/value 重复 C_{xy} 次放入 softmax 是等价的, 因为重复项有同样的 K, V , softmax 分母和加权 value 分子都会获得 multiplicity factor。这样既避免重复计算相同 key, 又保留 labelled multigraph 的权重结构。

在纯结构随机游走极限 $s_{xy} = 0$ 下, 权重正好是

$$\frac{C_{xy}}{\sum_z C_{xz}} = \frac{C_{xy}}{d^2},$$

即 P_{zz} 。因此继承扩张性定理可直接使用。

7.3 条件三: degree repair 后做 perturbation certificate

如果必须使用 pure boolean mask, 建议对去重后的 support 做 degree repair。目标是构造一个 r -in/ r -out regular directed graph A^{rep} , 并令

$$Q = \frac{1}{r} A^{\text{rep}}.$$

这保证 Q doubly stochastic。若还能证明或数值验证

$$\|Q - P_{zz}\|_2 \leq \delta,$$

则有

$$\begin{aligned} \|Q - J\|_2 &\leq \|P_{zz} - J\|_2 + \|Q - P_{zz}\|_2 \\ &\leq \rho_{zz} + \delta \end{aligned}$$

其中

$$\rho_{zz} = \sqrt{\lambda_G^2 + 2\mu_H^2 - \lambda_G^2\mu_H^2}.$$

因此只要

$$\rho_{zz} + \delta < 1,$$

修补后的 boolean mask 仍是 directed singular-value expander。

这里的关键不是 “boolean” 本身，而是要恢复两个性质：

近似/精确 in-out regularity 和 相对 labelled product 的小扰动。

7.4 条件四：非正则 boolean mask 的正确证书

若不做 repair, Q 通常只是 row-stochastic。这时不要再用 $\|Q - J\|_2$ 作为唯一理论证书。应计算 stationary distribution π , 并验证

$$\sigma_\pi(Q) = \left\| D_\pi^{1/2} (Q - \mathbf{1}\pi^\top) D_\pi^{-1/2} \right\|_2 < 1.$$

同时还要检查 π 是否接近均匀, 例如

$$\frac{\pi_{\max}}{\pi_{\min}} \quad \text{或} \quad \|\pi - u\|_2, \quad u = \frac{1}{T}\mathbf{1}.$$

若 $\sigma_\pi(Q) < 1$ 但 π 很不均匀, 则 mask 可能把信息带宽集中到少数 token; 这对某些 hub/global-token 结构可能有用, 但不再是 “每个 token 近似平等地看到全局” 的 expander attention。

如果 Q 与 labelled P 很接近, 可以给出 stationary distribution 的一个简单扰动界。设

$$\|P - J\|_2 \leq \rho < 1, \quad \|Q - P\|_2 \leq \delta.$$

若 Q 有 stationary distribution π , $u = T^{-1}\mathbf{1}$ 是 P 的 stationary distribution, 则

$$\|\pi - u\|_2 \leq \frac{\delta}{1 - \rho}.$$

证明是把

$$(\pi - u)^\top (I - P) = \pi^\top (Q - P)$$

限制在零和子空间上, 并使用 $(I - P)^{-1}$ 的范数界 $1/(1 - \rho)$ 。这个界只说明 stationary distribution 接近均匀; 要证明 mixing/contraction, 仍建议直接验证 $\sigma_\pi(Q)$ 。

8 Local complete block 与 remote zig-zag 的带权理论模型

boolean union 适合工程 mask, 但理论上更干净的是带权 mixture:

$$P_{\text{blk}} = \alpha P_{\text{loc}} + (1 - \alpha) P_{\text{zz}}, \quad P_{\text{loc}} = I_q \otimes J_B.$$

若按边数比例取权重, 则

$$\alpha = \frac{B}{B + d^2}.$$

P_{loc} 和 P_{zz} 都 doubly stochastic, 所以 P_{blk} doubly stochastic。设

$$\rho_{\text{zz}} = \|P_{\text{zz}} - J_{qB}\|_2 < 1.$$

因为 P_{loc} 只做 block 内平均, 不做 block 间混合, 在 $\mathbf{1}^\perp$ 上有

$$\|P_{\text{loc}} - J_{qB}\|_2 = 1.$$

于是

$$\|P_{\text{blk}} - J_{qB}\|_2 \leq \alpha + (1 - \alpha)\rho_{\text{zz}} < 1.$$

这说明 local dense block 不会破坏全局扩张性, 但会稀释 remote expander 的谱间隙。 B 越大, local 权重越重; 单层全局混合越慢, 但局部建模和 kernel 效率更好。这正是 trade-off 的数学形式。

9 有向扩展: Eulerian、非正则与 causal 情形

9.1 Eulerian directed expander

若 boolean 去重后满足

$$\deg^+(x) = \deg^-(x)$$

但不同 x 的度数不完全相同, 则图是 Eulerian directed graph。此时 row-normalized random walk 的 stationary distribution 为

$$\pi_x = \frac{\deg^+(x)}{\sum_z \deg^+(z)}.$$

如果度数比有常数界

$$\frac{d_{\max}}{d_{\min}} = O(1),$$

则 π 与均匀分布相差也有常数界。此时可以使用 $L_2(\pi)$ singular value 或 directed conductance 分析。若还要求每个 token 通信预算几乎相同, 则需要更强的近似正则条件

$$d_x = (1 \pm \varepsilon)d.$$

9.2 Causal/partial-order mask 不能是强连通 expander

若用于自回归 causal attention, 一层 mask 必须满足

$$y \leq x$$

才允许 query x 看 key y 。这种图是 DAG 或近似 DAG, 不可能强连通, 因此不可能有 stationary distribution 意义下的 directed expander mixing。对 causal 场景, 正确目标不是“向全局均匀混合”, 而是:

- 从每个当前位置到足够多历史 token 的可达性;
- 多层后以 $O(\log T)$ 深度覆盖历史;

- 每个历史 token 被读取的 indegree 不过度集中;
- 对任意历史区间或语义块, 有足够的 backward edges 进入。

这更像 directed acyclic lossless expander 或 layered bipartite expander, 而不是 stationary Markov expander。可以把层 ℓ 的 token 到层 $\ell + 1$ 的 token 视为二部图, 要求每个时间前缀或历史块在多层展开图中有良好扩张。

10 实验和实现 checklist

要验证这个结构是否形成闭环, 建议至少做四组指标。

10.1 复杂度闭环: 固定 B, d , 增加 q

固定 B, d , 令 $T = qB$ 增大。理论上

$$\frac{E_{\text{block}}}{E_{\text{full}}} \leq \frac{B + d^2}{T}.$$

实验应报告:

- theoretical pair count;
- 实际 unique key count $T(B + \bar{\nu} - \bar{o})$;
- forward/backward tokens/sec;
- peak memory;
- 与 full attention 的 wall-clock ratio。

若 kernel 足够好, 应看到相对 full attention 的优势随 T 增强; 若没有看到, 多半是 sparse layout 或 gather/scatter overhead 吃掉了 FLOPs 优势。

10.2 Trade-off 闭环: 固定 T , 扫描 B

固定总长度 T , 扫描

$$B \in \{8, 16, 32, 64, 128\}$$

以及若干 $d \leq B$ 。记录

$$B + d^2, \quad \lambda_G, \quad \mu_H, \quad \rho_{zz}, \quad \sigma_\pi(Q),$$

并报告任务 loss/perplexity 和速度。预期不是单调, 而是一个中间最优或 Pareto frontier。

10.3 Boolean 去重诊断

对每层、每个 head 统计

$$\nu_x = \#\{y : C_{xy} > 0\}, \quad \ell_x = d^2 - \nu_x,$$

以及

$$r_x, \quad c_x, \quad \frac{r_{\max}}{r_{\min}}, \quad \frac{c_{\max}}{c_{\min}}.$$

如果使用 pure boolean mask, 再计算 stationary distribution π 和

$$\sigma_\pi(Q).$$

如果使用 multiplicity bias, 则计算 labelled P_{zz} 的

$$\|P_{zz} - J\|_2$$

或用 power iteration 估计上界。

10.4 三种实现对比

建议比较:

1. **labelled duplicate 实现**: 重复 key/value, 最贴近理论, 但可能浪费计算。
2. **unique key + log C bias**: 理论等价 labelled multiplicity, 计算更省, 推荐作为主实现。
3. **pure boolean**: 最省边, 但需要 degree/ π / σ_π 诊断; 若失衡严重, 应做 repair。

11 最终可引用的修正版表述

下面这段可以直接放进论文或技术报告。

修正版 theorem statement

Let G be a B -in/ B -out regular directed graph on q clouds with a bijective rotation map $\text{Rot}_G : [q] \times [B] \rightarrow [q] \times [B]$. Let H be a d -in/ d -out regular directed graph on the port set $[B]$. Let P_G be the induced cloud-level doubly stochastic transition matrix and P_H the port-level transition matrix. Define

$$\lambda_G = \|P_G - J_q\|_2, \quad \mu_H = \|P_H - J_B\|_2.$$

The labelled directed zig-zag transition

$$P_{zz} = (I_q \otimes P_H) R_G (I_q \otimes P_H)$$

is doubly stochastic and satisfies

$$\|P_{zz} - J_{qB}\|_2 \leq \sqrt{\lambda_G^2 + 2\mu_H^2 - \lambda_G^2 \mu_H^2}.$$

Consequently, if $\lambda_G^2 + 2\mu_H^2 < 1$, the labelled product is a directed singular-value expander. For attention, this guarantee applies directly to the multigraph/multiplicity-preserving mask. If duplicate targets are collapsed into a boolean mask, the resulting row-normalized transition matrix need not be doubly stochastic and the above guarantee does not automatically apply. The guarantee is preserved under either collision-freeness, multiplicity weights C_{xy} , or an explicit in/out-regular repair plus a perturbation certificate.

修正版 complexity statement

For block size $B = mn$, number of blocks q , total tokens $T = qB$, and port graph degree d , the labelled remote zig-zag paths per query equal d^2 . If the implementation uses a boolean mask, let ν_x be the number of distinct remote keys reached by query x and let o_x be the number of such keys already covered by the local complete block. Then

$$E_{\text{block}}^{\text{bool}} = \sum_x (B + \nu_x - o_x) = T(B + \bar{\nu} - \bar{o}) \leq T(B + d^2).$$

Therefore the mask-related attention cost is

$$\Theta(T(B + \bar{\nu} - \bar{o})d_{\text{model}}) \leq \Theta(T(B + d^2)d_{\text{model}}).$$

The equality $T(B + d^2)$ is valid only for labelled/multiplicity counting or under no-collision/no-local-overlap assumptions.

12 参考文献

- [1] Omer Reingold, Salil Vadhan, and Avi Wigderson. *Entropy waves, the zig-zag graph product, and new constant-degree expanders*. Annals of Mathematics, 155(1):157–187, 2002.
- [2] Shlomo Hoory, Nathan Linial, and Avi Wigderson. *Expander graphs and their applications*. Bulletin of the American Mathematical Society, 43(4):439–561, 2006.
- [3] Fan R. K. Chung. *Spectral Graph Theory*. CBMS Regional Conference Series in Mathematics, No. 92, American Mathematical Society, 1997.
- [4] Fan Chung. *Laplacians and the Cheeger inequality for directed graphs*. Annals of Combinatorics, 9:1–19, 2005.
- [5] David A. Levin, Yuval Peres, and Elizabeth L. Wilmer. *Markov Chains and Mixing Times*. American Mathematical Society, 2009.
- [6] Rajendra Bhatia. *Matrix Analysis*. Springer, 1997.
- [7] Manzil Zaheer et al. *Big Bird: Transformers for Longer Sequences*. Advances in Neural Information Processing Systems, 2020.
- [8] Hamed Shirzad et al. *Exphormer: Sparse Transformers for Graphs*. Proceedings of ICML, 2023.
- [9] Tri Dao et al. *FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness*. Advances in Neural Information Processing Systems, 2022.