

与Directed Block Zig-Zag Attention 理论对齐的工程实现方案

Ye Su

2026-06-12

Abstract

本文给出一套与directed block zig-zag attention 理论严格对齐的工程实现方案。核心原则是：实现中的attention mask 必须对应理论证明中的labelled/multigraph/保留重数的directed zig-zag transition，或者给出从实际boolean mask 到该理论对象的扰动证书。为避免实现与理论脱节，本文明确规定大图 G 、小端口图 H 、旋转映射 R_G 、multiplicity-preserving attention、图结构诊断、实验任务和baseline 的构造方式。Especially，本文不建议把cycle-like H 和cyclic G 作为主方法，因为它们通常不能满足有向奇异值扩张条件；也不建议用固定位置的copy_first 作为主要证据，因为该任务容易被稀疏mask 的直接捷径解决。

Contents

1	目标与总体原则	2
2	符号定义	3
3	理论对象：Labelled Directed Zig-Zag Transition	3
3.1	Local complete block	3
3.2	小端口图 H	3
3.3	大图 G 与旋转映射	4
3.4	Directed zig-zag remote paths	4
4	奇异值扩张性要求	4
5	为什么不能使用Cycle-like H 作为主方法	5
6	与理论对齐的图构造	5
6.1	构造 G ： B 个随机置换	5
6.2	构造 H ： d 个端口置换	6
6.3	重采样准则	6
7	Multiplicity-preserving Attention 实现	6
7.1	总multiplicity 定义	6
7.2	Unique key + log multiplicity bias	7
7.3	等价性说明	7
8	Mask 构造伪代码	7

9 必须报告的图结构诊断	8
9.1 双射检查	8
9.2 Doubly stochastic 检查	8
9.3 谱诊断	8
9.4 Collision 与overlap 诊断	9
9.5 Pure boolean 消融的额外诊断	9
10 复杂度口径	10
11 任务设计：避免固定位置捷径	10
11.1 Shortcut 诊断	10
11.2 推荐任务	11
12 Baseline 设计	11
13 实验矩阵	11
13.1 复杂度闭环	11
13.2 Trade-off 闭环	12
13.3 随机种子	12
14 最终推荐主方法	12
15 总结	13

1 目标与总体原则

本方法的目标是在长序列self-attention 中，用local dense block 加directed zig-zag cross-block sparse attention 替代全局完全图attention，从而把mask-related attention pair 数从

$$\Theta(N^2)$$

降低到

$$O(N(B + d^2)),$$

其中 N 是token 总数， B 是每个局部block 的token 数， d 是小端口图 H 的出度。

为了与理论严格对齐，本文采用如下原则：

1. 大图 G 必须是 B -in/ B -out regular directed graph。
2. 小图 H 必须是 d -in/ d -out regular directed graph。
3. 大图的端口旋转映射

$$R_G : [q] \times [B] \rightarrow [q] \times [B]$$

必须是双射。

4. 主实现不采用pure boolean 去重，而采用

$$\text{unique key} + \log M_{xy} \text{ multiplicity bias}$$

的multiplicity-preserving 实现。

5. 每个实验配置必须报告图结构证书，包括

$$\lambda_G, \quad \mu_H, \quad \rho_{\text{bound}}, \quad \rho_{\text{exact}},$$

以及collision、local overlap、in/out degree imbalance 等诊断指标。

6. 实验任务必须避免固定位置捷径，不能仅使用`copy_first` 作为长程建模证据。

2 符号定义

设序列长度为 N ，block 大小为 B ，block 数为

$$q = \frac{N}{B}.$$

本文默认 $B \mid N$ 。每个token 写成二元组

$$x = (v, i),$$

其中

$$v \in [q] = 0, 1, \dots, q-1$$

表示block 编号，

$$i \in [B] = 0, 1, \dots, B-1$$

表示block 内端口或token 编号。全局token index 定义为

$$\text{idx}(v, i) = vB + i.$$

3 理论对象：Labelled Directed Zig-Zag Transition

3.1 Local complete block

对于任意query token $x = (v, i)$ ，local complete block 的key 集合定义为

$$\mathcal{N}_{\text{loc}}(v, i) = (v, j) : j \in [B].$$

因此每个token 在局部block 内有 B 个local keys。

3.2 小端口图 H

小图 H 定义在端口集合 $[B]$ 上。令

$$N_H^+(i) = h_a(i) : a = 1, \dots, d$$

表示端口 i 的 d 个有向出邻居。对应的归一化转移矩阵为

$$P_H \in \mathbb{R}^{B \times B}.$$

工程上要求 H 是 d -in/ d -out regular directed graph，因此

$$P_H \mathbf{1}_B = \mathbf{1}_B, \quad \mathbf{1}_B^\top P_H = \mathbf{1}_B^\top.$$

即 P_H 是doubly stochastic。定义

$$J_B = \frac{1}{B} \mathbf{1}_B \mathbf{1}_B^\top,$$

以及小图的directed singular expansion parameter:

$$\mu_H = \|P_H - J_B\|_2.$$

3.3 大图 G 与旋转映射

大图 G 定义在block 集合 $[q]$ 上。每个block 有 B 个出端口和 B 个入端口。其directed rotation map 为

$$R_G : [q] \times [B] \rightarrow [q] \times [B].$$

若

$$R_G(v, p) = (w, r),$$

表示从block v 的出端口 p 跳到block w , 并在block w 的入端口 r 到达。严格要求 R_G 必须是 $[q] \times [B]$ 上的双射。

大图诱导的block-level transition matrix 记为 $P_G \in \mathbb{R}^{q \times q}$ 。采用列向量信号约定时, 可定义

$$(P_G)_{wv} = \frac{1}{B} \text{card } p \in [B] : R_G(v, p) = (w, r) \text{ for some } r.$$

因为 G 是 B -in/ B -out regular directed graph, 所以

$$P_G \mathbf{1}_q = \mathbf{1}_q, \quad \mathbf{1}_q^\top P_G = \mathbf{1}_q^\top.$$

定义

$$J_q = \frac{1}{q} \mathbf{1}_q \mathbf{1}_q^\top,$$

以及

$$\lambda_G = \|P_G - J_q\|_2.$$

3.4 Directed zig-zag remote paths

对query token

$$x = (v, i),$$

一次directed zig-zag remote path 为

$$(v, i) \xrightarrow{H} (v, p) \xrightarrow{G} (w, r) \xrightarrow{H} (w, j),$$

其中

$$p \in N_H^+(i), \quad (w, r) = R_G(v, p), \quad j \in N_H^+(r).$$

由于第一步 H 有 d 种选择, 第三步 H 也有 d 种选择, 因此每个query token 有 d^2 条labelled remote paths。定义multiplicity:

$$C_{xy} = \text{card } (a, b) \in [d] \times [d] : \text{zz}(x, a, b) = y.$$

labelled remote transition 为

$$P_{\text{zz}, xy} = \frac{C_{xy}}{d^2}.$$

4 奇异值扩张性要求

令

$$P_{\text{zz}} = (I_q \otimes P_H) R_G (I_q \otimes P_H).$$

其中 R_G 也表示旋转映射对应的permutation matrix。理论上, 若

$$\lambda_G = \|P_G - J_q\| * 2, \quad \mu_H = \|P_H - J_B\| * 2,$$

则labelled directed zig-zag transition 满足

$$|P * zz - J * qB| * 2 \leq \sqrt{\lambda_G^2 + 2\mu_H^2 - \lambda_G^2 \mu_H^2},$$

其中

$$J * qB = J_q \otimes J_B.$$

因此，主方法的图构造必须满足

$$\rho_{\text{bound}} = \sqrt{\lambda_G^2 + 2\mu_H^2 - \lambda_G^2 \mu_H^2} < 1.$$

一个更强但更简单的充分条件是

$$\lambda_G^2 + 2\mu_H^2 < 1.$$

若该条件不满足，则该配置只能称为sparse attention pattern，不能称为expander-aligned zig-zag attention。

5 为什么不能使用Cycle-like H 作为主方法

如果 H 取cycle-neighbor 结构，例如

$$H(i) = (i + 1) \bmod B, (i - 1) \bmod B,$$

则 H 本质上是cycle graph 的有向或无向邻接形式。对于较小的 B ，其第二奇异值通常接近1。例如当 $B = 16, d = 2$ 时，cycle random walk 的第二奇异值大约接近

$$\cos\left(\frac{2\pi}{16}\right) \approx 0.924.$$

此时

$$2\mu_H^2 > 1,$$

即使大图 G 完美，也无法满足

$$\lambda_G^2 + 2\mu_H^2 < 1.$$

因此，cycle-like H 不应作为理论对齐的主方法，只能作为非扩张稀疏结构baseline。

6 与理论对齐的图构造

6.1 构造 G ： B 个随机置换

推荐用 B 个block-level permutation 构造大图 G 。令

$$\pi_0, \pi_1, \dots, \pi_{B-1}$$

为 $[q]$ 上的 B 个置换。定义

$$R_G(v, p) = (\pi_p(v), p).$$

此时 R_G 自动是 $[q] \times [B]$ 上的双射。为了减少self-loop，可以要求 π_p 为derangement：

$$\pi_p(v) \neq v, \quad \forall v.$$

为了减少parallel edges，可以在采样时限制同一 $v \rightarrow w$ 的重复次数。

6.2 构造 H : d 个端口置换

推荐用 d 个端口置换构造小图 H 。令

$$\sigma_0, \sigma_1, \dots, \sigma_{d-1}$$

为 $[B]$ 上的置换。定义

$$N_H^+(i) = \sigma_a(i) : a = 0, \dots, d-1.$$

则

$$P_H = \frac{1}{d} \sum_{a=0}^{d-1} S_{\sigma_a},$$

其中 S_{σ_a} 是置换矩阵。这样构造出的 P_H 自动doubly stochastic。

6.3 重采样准则

采样 G, H 后, 必须计算

$$\lambda_G = |P_G - J_q|_2, \quad \mu_H = |P_H - J_B|_2.$$

若

$$\lambda_G^2 + 2\mu_H^2 \geq 1,$$

则该图结构不能作为主方法, 应重新采样或增加 d 、增大 B 。推荐搜索范围为

$$B \in 16, 32, 64, 128, \quad d \in 4, 6, 8.$$

不建议从 $d = 2$ 开始作为主配置, 因为 $d = 2$ 很难得到足够小的 μ_H 。

7 Multiplicity-preserving Attention 实现

7.1 总multiplicity 定义

为了把local complete block 和remote zig-zag 放进同一个softmax, 定义总multiplicity:

$$M_{xy} = \mathbf{1}_{y \in \mathcal{N}_{\text{loc}}(x)} + C_{xy}.$$

于是每个query 的labelled edge 总数为

$$\sum_y M_{xy} = B + d^2.$$

若remote path 落回local block, 不应简单丢弃, 而应把multiplicity 相加。因为理论对象是labelled/multigraph transition, 而不是boolean union。

7.2 Unique key + log multiplicity bias

工程上不需要真的重复key/value。对每个query x ，只存储unique keys:

$$\mathcal{N}(x) = \{y : M_{xy} > 0\},$$

并对每条unique pair (x, y) 存储

$$\log M_{xy}.$$

标准attention score 为

$$s_{xy}^{(h)} = \frac{(q_x^{(h)})^\top k_y^{(h)}}{\sqrt{d_h}}.$$

加入multiplicity bias 后:

$$\tilde{s}_{xy}^{(h)} = s_{xy}^{(h)} + \log M_{xy}.$$

然后计算

$$\alpha_{xy}^{(h)} = \frac{\exp(\tilde{s}_{xy}^{(h)})}{\sum_{z \in \mathcal{N}(x)} \exp(\tilde{s}_{xz}^{(h)})}.$$

输出为

$$o_x^{(h)} = \sum_{y \in \mathcal{N}(x)} \alpha_{xy}^{(h)} v_y^{(h)}.$$

7.3 等价性说明

若重复路径到达同一个key y ，且这些路径使用相同的key/value，即 K_y, V_y 相同，则真实重复 M_{xy} 次的softmax 权重贡献为

$$M_{xy} \exp(s_{xy}).$$

而unique key 加log multiplicity bias 后:

$$\exp(s_{xy} + \log M_{xy}) = M_{xy} \exp(s_{xy}).$$

因此二者等价。

备注. 该等价性要求重复路径共享同一个 K_y, V_y ，且没有不同的路径级bias。若存在路径级bias b_p ，则应使用

$$\log \sum_{p: x \rightarrow y} \exp(b_p)$$

替代简单的 $\log M_{xy}$ 。

8 Mask 构造伪代码

下面给出multiplicity-preserving block-zigzag attention mask 的论文式伪代码(Algorithm 1)。算法输入为序列长度(N)、block 大小(B)、端口图出度(d)、小图端口邻接表(H_{out})，以及大图旋转映射(Rot_G)。输出为每个query token 对应的unique key index 集合($\mathcal{I}$)，以及与之对应的log-multiplicity bias ($\mathcal{L}$)。

Algorithm 1 Multiplicity-preserving Block-Zigzag Attention Mask Construction

Input: Sequence length N , block size B , port degree d , port-neighbor list H_{out} , rotation map Rot_G

Output: Unique key indices $\mathcal{I}$ and log-multiplicity bias $\mathcal{L}$

```
1:  $q \leftarrow N/B$ 
2: for  $x = 0, \dots, N - 1$  do
3:    $v \leftarrow \lfloor x/B \rfloor$ 
4:    $i \leftarrow x \bmod B$ 
5:   Initialize an empty associative array  $\mathcal{C}$ 
6:   for  $j = 0, \dots, B - 1$  do
7:      $y \leftarrow vB + j$  local complete block
8:      $\mathcal{C}[y] \leftarrow \mathcal{C}[y] + 1$ 
9:   end for
10:  for  $p \in H_{\text{out}}[i]$  do
11:     $(w, r) \leftarrow \text{Rot}_G(v, p)$  remote zig-zag path
12:    for  $j \in H_{\text{out}}[r]$  do
13:       $y \leftarrow wB + j$ 
14:       $\mathcal{C}[y] \leftarrow \mathcal{C}[y] + 1$ 
15:    end for
16:  end for
17:   $\mathcal{I}[x] \leftarrow \text{Sort}(\text{Keys}(\mathcal{C}))$ 
18:   $\mathcal{L}[x] \leftarrow [\log \mathcal{C}[y] : y \in \mathcal{I}[x]]$ 
19: end for
20: return  $\mathcal{I}, \mathcal{L}$ 
```

9 必须报告的图结构诊断

每个实验配置必须先报告图结构诊断，再报告训练结果。

9.1 双射检查

检查

$$R_G : [q] \times [B] \rightarrow [q] \times [B]$$

是否为双射:

$$|R_G(v, p) : v \in [q], p \in [B]| = qB.$$

9.2 Doubly stochastic 检查

检查

$$P_G \mathbf{1}_q = \mathbf{1}_q, \quad \mathbf{1}_q^\top P_G = \mathbf{1}_q^\top,$$

以及

$$P_H \mathbf{1}_B = \mathbf{1}_B, \quad \mathbf{1}_B^\top P_H = \mathbf{1}_B^\top.$$

9.3 谱诊断

报告

$$\lambda_G = |P_G - J_q| * 2,$$

$$\mu_H = |P_H - J_B| * 2,$$

以及

$$\rho * \text{bound} = \sqrt{\lambda_G^2 + 2\mu_H^2 - \lambda_G^2 \mu_H^2}.$$

对中小规模 N , 直接构造 $P * \text{zz}$, 报告

$$\rho_{\text{exact}} = |P_{\text{zz}} - J_{qB}| * 2.$$

应满足

$$\rho * \text{exact} \leq \rho_{\text{bound}} + \varepsilon.$$

9.4 Collision 与overlap 诊断

对每个query x , 统计:

$$\nu_x = \text{card } y : C_{xy} > 0, \quad \ell_x = d^2 - \nu_x, \quad o_x = \text{card } y : C_{xy} > 0, \quad y \in \mathcal{N}_{\text{loc}}(x).$$

报告

$$\bar{\nu}, \quad \bar{\ell}, \quad \bar{o}.$$

真实unique key 数为

$$K_x^{\text{unique}} = \text{card } y : M_{xy} > 0,$$

并满足

$$K_x^{\text{unique}} \leq B + d^2.$$

9.5 Pure boolean 消融的额外诊断

若使用pure boolean mask, 则定义

$$A_{xy} = \mathbf{1} M_{xy} > 0,$$

$$r_x = \sum_y A_{xy}, \quad c_y = \sum_x A_{xy}.$$

row-normalized boolean transition 为

$$Q_{xy} = \frac{A_{xy}}{r_x}.$$

必须报告

$$r_{\min}, \quad r_{\max}, \quad c_{\min}, \quad c_{\max}, \quad \frac{r_{\max}}{r_{\min}}, \quad \frac{c_{\max}}{c_{\min}}.$$

还应计算stationary distribution

$$\pi^\top Q = \pi^\top$$

并报告

$$|\pi - u|_2, \quad u = \frac{1}{N} \mathbf{1}.$$

如果 π 明显偏离均匀分布, 则该pure boolean mask 不再对应均匀通信的expander attention。

10 复杂度口径

Labelled 远程路径每个query 有 d^2 条, local complete block 有 B 条。因此raw labelled key 数为

$$K_{\text{raw}} = B + d^2.$$

raw labelled attention pair 数为

$$E_{\text{raw}} = N(B + d^2).$$

若实现采用unique key + log multiplicity bias, 真实计算的unique pair 数为

$$E_{\text{unique}} = \sum_x \text{card } y : M_{xy} > 0 \leq N(B + d^2).$$

mask-related attention FLOPs 为

$$\text{FLOPs} * \text{mask} = \Theta(E * \text{unique} d_{\text{model}}),$$

并有上界

$$\text{FLOPs} * \text{mask} = O(N(B + d^2)d * \text{model}).$$

注意: 不能写成

$$\Theta(E_{\text{unique}} d_{\text{model}}) \leq \Theta(N(B + d^2)d_{\text{model}}),$$

因为 $\Theta(\cdot)$ 是函数类, 不应直接放入不等式。应使用 $O(\cdot)$ 表示上界。完整Transformer block 还包含QKV/output projection 和FFN, 其复杂度通常为

$$\Theta(Nd_{\text{model}}^2) + \Theta(E_{\text{unique}} d_{\text{model}}) + \Theta(Nd_{\text{model}} d_{\text{ff}}).$$

11 任务设计: 避免固定位置捷径

不建议仅使用`copy_first` 作为主要任务。原因是固定从最后token 预测第一个token 时, 某些hand-crafted cyclic mask 可能让最后token 一跳直接attend 到第一个token。这种情况验证的是结构捷径, 而不是多层全局混合能力。

11.1 Shortcut 诊断

对每个样本, 设query 位置为 t , 目标位置为 p 。必须计算mask 图上的最短路径:

$$\text{dist}_{\text{mask}}(t, p).$$

报告

`target_in_1hop_rate`, `target_in_2hop_rate`, `target_in_Lhop_rate`,

以及

`average_shortest_path`, `unreachable_rate`.

如果某个任务中目标token 大量位于query token 的1-hop reachable set 内, 则该任务不能作为长程多跳传播证据。

11.2 推荐任务

主实验应使用随机化目标位置或内容寻址任务，例如：

1. **Random Position Copy**: 随机采样目标位置 p ，模型根据query 预测 x_p 。
2. **Selective Retrieval**: 在长噪声序列中随机插入marker 和目标token，模型输出marker 关联的目标。
3. **Needle-lite**: 在随机位置插入needle，最后询问needle 内容。
4. **Associative Recall**: 输入key-value pairs 和query key，输出对应value。
5. **Induction Head**: 构造 $A, B, \dots, A, ?$ ，要求预测 B 。

12 Baseline 设计

为了公平比较，至少需要以下baseline：

1. **Dense**: 完整self-attention，作为质量上界。
2. **Local-only**: 只看同block，检验跨block 边是否必要。
3. **Local + random row-only**: 每个query 随机选 d^2 个remote keys。
4. **Local + random regular**: 使用随机置换构造 d^2 -in/ d^2 -out regular remote graph。
5. **Local + BigBird-style**: local window + random + global token。
6. **Local + directed zig-zag multiplicity**: 重复边实现，最贴近理论。
7. **Local + directed zig-zag unique + $\log M_{xy}$** : 主工程实现。
8. **Local + directed zig-zag pure boolean**: 消融，用于观察丢弃multiplicity 的影响。

其中最重要的公平baseline 是random regular same-budget，而不是普通row-only random。因为row-only random 可能造成column degree 不均匀，导致hub 或负载不公平。

13 实验矩阵

13.1 复杂度闭环

固定 B, d ，增加 N 。例如

$$B = 32, \quad d = 4,$$

$$N \in 512, 1024, 2048, 4096, 8192.$$

报告

$$N^2, \quad N(B + d^2), \quad E_{\text{unique}}.$$

同时报告

forward time, backward time, tokens/sec, peak memory.

13.2 Trade-off 闭环

固定 N ，扫描 B, d 。例如

$$\begin{aligned} N &= 4096, \\ B &\in 16, 32, 64, 128, \\ d &\in 2, 4, 6, 8. \end{aligned}$$

只把满足

$$\lambda_G^2 + 2\mu_H^2 < 1$$

的配置标记为expander-aligned 配置。否则只能标记为sparse-but-not-certified-expander。

13.3 随机种子

实验至少需要5 个graph seeds，以及5 个training seeds。报告平均值和标准差，避免把单个mask seed 或单个training seed 的偶然成功误认为方法优势。

14 最终推荐主方法

最终推荐的工程主方法为：

Local complete block + certified directed zig-zag remote + unique key with $\log M_{xy}$ multiplicity bias.

具体要求如下：

1. 用随机置换构造 B -in/ B -out regular directed G 。
2. 用随机端口置换构造 d -in/ d -out regular directed H 。
3. 重采样 G, H ，直到满足

$$\lambda_G^2 + 2\mu_H^2 < 1.$$

4. 预计算

$$M_{xy} = \mathbf{1}_{y \in \mathcal{N}_{\text{loc}}(x)} + C_{xy}.$$

5. Attention logits 使用

$$s_{xy} + \log M_{xy}.$$

6. 报告

$$\lambda_G, \quad \mu_H, \quad \rho_{\text{bound}}, \quad \rho_{\text{exact}}, \quad \bar{\nu}, \quad \bar{o},$$

以及in/out degree 统计。

7. 使用random-position retrieval、selective retrieval、needle-lite、associative recall 等任务，避免固定位置捷径。
8. 使用equal-budget random regular attention 作为关键baseline。

15 总结

要让工程实现与理论严格对齐，关键不是简单写一个zig-zag sparse mask，而是保证实现对象与理论证明对象一致。理论证明对应的是labelled/multigraph/multiplicity-preserving directed zig-zag transition，因此工程上应使用unique key + $\log M_{xy}$ bias 保留multiplicity，而不是直接使用pure boolean mask。

同时， G, H 不能使用未验证的cycle/cyclic 结构作为主方法，而必须构造并验证directed singular-value expansion:

$$\lambda_G^2 + 2\mu_H^2 < 1.$$

只有当mask 构造、multiplicity 处理、谱诊断和实验任务都满足上述要求时，实验结果才可以被解释为与directed block-zigzag expander 理论对齐。