

固定 $m \times n$ Token 完全图与 Zig-Zag 乘法 Block 的复杂度

Qi 的模型设计笔记

2026-06-09

摘要

设每个局部 dense block 含有 $B = mn$ 个 token，块内使用完全图注意力；不同 block 之间用 zig-zag product 或其邻居 oracle 生成稀疏跨块边。若共有 q 个这样的 block，总 token 数为 $T = qB$ 。在最自然的“token 等于端口”配置下，zig-zag 跨块部分每个 token 只产生 d^2 条跨块边，因此 mask 相关的注意力复杂度为

$$\Theta(q(B^2 + Bd^2)d_{\text{model}}) = \Theta(T(B + d^2)d_{\text{model}}).$$

当 $B = mn$ 和 d 都是常数时，该 block 对总 token 数 T 是线性的；如果把小图 H 也取成完全图 K_B ，则 $d = B - 1$ ，zig-zag 项会膨胀为 $\Theta(qB^3d_{\text{model}})$ ，通常不是推荐做法。

1 符号和结构

符号	含义
$B = mn$	每个局部 block 中的 token 数，排成 $m \times n$ 。
q	block 数，也可理解为“云”的数量。
$T = qB$	总 token 数。
d_{model}	多头注意力合并后的 hidden width。若有 h 个 head、每头宽度 r ，则 $d_{\text{model}} = hr$ 。
G	block-level 大图；标准 zig-zag product 中要求 G 是 Δ -正则图。
H	port-level 小图；标准 zig-zag product 中 H 的顶点数为 Δ ，度数为 d 。
d	小图 H 的度数；zig-zag product 后的新图度数为 d^2 。

本文把一个 block 的 mask 分成两部分：

$$\mathcal{E}_{\text{block}} = \mathcal{E}_{\text{local complete}} \cup \mathcal{E}_{\text{zigzag}}.$$

其中 $\mathcal{E}_{\text{local complete}}$ 是每个 $m \times n$ token block 内部的完全图， $\mathcal{E}_{\text{zigzag}}$ 是跨 block 的 zig-zag 稀疏边。

注意标准 zig-zag 的端口一致性。 若 G 是 Δ -正则、 H 是 d -正则且 $|V(H)| = \Delta$ ，则

$$V(G \mathbin{\textcircled{Z}} H) = V(G) \times [\Delta], \quad \deg(G \mathbin{\textcircled{Z}} H) = d^2.$$

因此 product 后的 token 数是 $q\Delta$ 。若希望它正好等于 qB ，最直接的匹配是

$$\Delta = B = mn.$$

也就是说：每个局部 block 的 B 个 token 同时充当该 block 的 B 个端口。

2 块内完全图复杂度

一个 B 点完全图 K_B 的无向边数为

$$|E(K_B)| = \frac{B(B-1)}{2}.$$

注意力通常按有向 query-key pair 计算；若包含 self-loop，则每个 block 的有向 pair 数是

$$E_{\text{local, per block}}^{\rightarrow} = B^2,$$

若不含 self-loop，则是 $B(B-1)$ 。复杂度量级相同。共有 q 个 block 时

$$E_{\text{local}}^{\rightarrow} = qB^2 = q(mn)^2 = Tmn.$$

因此 local dense attention 的 score 与 value 聚合的 mask 相关 FLOPs 为

$$\text{FLOPs}_{\text{local}} = \Theta(qB^2 d_{\text{model}}) = \Theta(qm^2 n^2 d_{\text{model}}) = \Theta(Tmnd_{\text{model}}).$$

这里忽略 softmax 的常数项；softmax 与 attention score 的存储是 $\Theta(hqB^2)$ 。

3 跨 block 的 zig-zag 复杂度

标准 zig-zag product 的一步是

$$\text{zig in } H \longrightarrow \text{jump in } G \longrightarrow \text{zag in } H.$$

给定当前顶点 (v, i) 和两个小图边标号 (a, b) ，只需做两次 H 的旋转映射和一次 G 的旋转映射：

$$(v, i) \xrightarrow{H, a} (v, i') \xrightarrow{G} (w, j') \xrightarrow{H, b} (w, j).$$

因为 $(a, b) \in [d] \times [d]$ ，每个 token 的 zig-zag 邻居数为 d^2 。若采用 $\Delta = B = mn$ 的端口匹配，则

$$E_{\text{zz}}^{\rightarrow} = qBd^2 = qmn d^2 = Td^2.$$

对应的跨块注意力 FLOPs 为

$$\text{FLOPs}_{\text{zz}} = \Theta(qBd^2 d_{\text{model}}) = \Theta(qmn d^2 d_{\text{model}}) = \Theta(Td^2 d_{\text{model}}).$$

edge list 或 attention score 的显存为 $\Theta(qBd^2)$ ，若每个 head 单独存 score，则是 $\Theta(hqBd^2)$ 。

邻居 oracle / mask 构造时间。 设 t_G 是计算一次 G 的旋转映射的时间, t_H 是计算一次 H 的旋转映射的时间。则单个 zig-zag 邻居的生成时间为

$$\Theta(t_G + 2t_H).$$

如果 G, H 都是显式构造且旋转映射为 $O(1)$, 则构造全部 zig-zag 邻接表的时间是

$$\Theta(qBd^2) = \Theta(Td^2).$$

如果每层复用同一 mask, 这部分可以预计算; 如果每层重采样, 则每层都要付这项构造成本。

4 总复杂度结论

忽略 QKV projection、output projection 和 MLP, 只看 mask 相关的 attention score 与 value mixing:

$$\begin{aligned} E_{\text{block}}^{\rightarrow} &= E_{\text{local}}^{\rightarrow} + E_{\text{zz}}^{\rightarrow} \\ &= qB^2 + qBd^2 \\ &= qB(B + d^2) \\ &= T(B + d^2). \end{aligned}$$

所以

$$\text{FLOPs}_{\text{attn,mask}} = \Theta(qB(B + d^2)d_{\text{model}}) = \Theta(T(B + d^2)d_{\text{model}}).$$

代入 $B = mn$:

$$\text{FLOPs}_{\text{attn,mask}} = \Theta(qmn(mn + d^2)d_{\text{model}}).$$

对应的 score 显存为

$$\text{Memory}_{\text{score}} = \Theta(hqmn(mn + d^2)).$$

如果把线性层也计入, 一个 Transformer-like block 的主要项可以写成

$$\Theta(Td_{\text{model}}^2) + \Theta(T(B + d^2)d_{\text{model}}) + \Theta(Td_{\text{model}}d_{\text{ff}})$$

其中三项分别对应 QKV/output projection、稀疏 attention、FFN。若讨论图结构本身的复杂度, 通常只看中间的 mask 相关项。

主结论

若 $B = mn$ 固定, 且 zig-zag 小图 H 的度数 $d = O(1)$, 则

$$E_{\text{block}}^{\rightarrow} = \Theta(q), \quad \text{FLOPs}_{\text{attn,mask}} = \Theta(qd_{\text{model}}) = \Theta(Td_{\text{model}}).$$

也就是说: 对总 token 数线性。真正的常数是 $B + d^2 = mn + d^2$; 局部 complete block 贡献 mn , 跨块 zig-zag 贡献 d^2 。

5 和全局完全图 attention 的比较

如果在全部 $T = qB$ 个 token 上直接做 dense self-attention, 则有向 pair 数为

$$E_{\text{full}}^{\rightarrow} = T^2 = q^2 B^2.$$

而本文 block 的 pair 数是

$$E_{\text{block}}^{\rightarrow} = qB(B + d^2).$$

因此 edge/pair 级别的理论节省比例为

$$\boxed{\frac{E_{\text{full}}^{\rightarrow}}{E_{\text{block}}^{\rightarrow}} = \frac{q^2 B^2}{qB(B + d^2)} = \frac{qB}{B + d^2}.}$$

若 $d = O(1)$ 且 $B = mn$ 固定, 则节省比例约为 $\Theta(q)$ 。直观上: 全局完全图把所有 block 两两 dense 连接; 这里每个 block 内 dense, 跨 block 只保留 constant-degree 的 expander/zig-zag 通信。

6 几个重要变体

6.1 如果把小图 H 也取成完全图 K_B

如果 zig-zag 中的小图 H 是 K_B , 则 $d = B - 1$ 。于是

$$E_{\text{zz}}^{\rightarrow} = qB(B - 1)^2 = \Theta(qB^3),$$

总复杂度变成

$$\text{FLOPs}_{\text{attn,mask}} = \Theta((qB^2 + qB^3)d_{\text{model}}) = \Theta(qB^3d_{\text{model}}).$$

代入 $B = mn$:

$$\boxed{\text{FLOPs} = \Theta(q(mn)^3d_{\text{model}}).}$$

这仍然在 B 固定时对 q 线性, 但常数是 $(mn)^3$, 通常很大。因此更推荐:

块内用 K_B 做 dense local attention, zig-zag 的 H 用常数度 expander。

6.2 如果对每一对 block 都单独做一次 zig-zag

上面的主结论默认 G 是一个稀疏 block-level 图: 每个 block 只通过 G 的端口与少数结构化 block 通信。若你真正的设计是“任意两个不同 block 之间都做一套 zig-zag”, 则跨块项会多出 $\Theta(q)$ 倍:

$$E_{\text{zz,pairwise}}^{\rightarrow} = \Theta(q^2 B d^2),$$

从而

$$\boxed{\text{FLOPs}_{\text{pairwise}} = \Theta((qB^2 + q^2 B d^2)d_{\text{model}}).}$$

若 $d = O(1)$, 这相当于 $\Theta(q^2 B d_{\text{model}})$ 的跨块复杂度, 不再对 T 线性; 它相对于全局 dense attention $\Theta(q^2 B^2 d_{\text{model}})$ 的节省比例约为 B/d^2 。

6.3 如果 $\Delta \neq B$

标准 zig-zag product 满足 $|V(G \circledast H)| = q\Delta$ 。如果每个 dense block 有 B 个 token，但 block-level 图 G 的度数是 $\Delta \neq B$ ，则需要一个 token-port 映射：

$$\text{tokens } [B] \rightarrow \text{ports } [\Delta] \rightarrow \text{tokens } [B].$$

这会引入额外的 gather/scatter 或 pooling 成本。纯 product 部分为

$$E_{zz}^{\rightarrow} = q\Delta d^2,$$

再叠加 token-port 映射成本。若目标是最简洁的复杂度和实现，取 $\Delta = B = mn$ 最干净。

7 工程解释

- 块内 complete graph 给每个 $m \times n$ 局部 patch 充分 pairwise 比较，代价是 $\Theta(B^2)$ 每块。
- 跨块 zig-zag 给全局通信通道，若 H 是常数度 expander，每个 token 只额外看 d^2 个跨块 token。
- 因此该 block 的瓶颈不是 zig-zag，而是局部 complete block 的 $B^2 = (mn)^2$ 。固定 m, n 后，这个瓶颈变成常数。
- 若选择 $H = K_B$ ，则 zig-zag 从 sparse 退化成 high-degree，复杂度会从 qBd^2 变成 qB^3 。
- 实际 GPU 上若直接用非结构化 sparse gather/scatter，常数可能很差；最好让 local dense 用 block kernel，zig-zag 边用可缓存的 edge list 或 block-sparse layout。

8 最终可直接引用的公式

设 $B = mn$ 、 $T = qB$ ，且 zig-zag 小图度数为 d 。则一个 block 的 mask 相关复杂度为

$\begin{aligned} \text{有向 attention pair 数} &= \Theta(qmn(mn + d^2)), \\ \text{attention FLOPs} &= \Theta(qmn(mn + d^2)d_{\text{model}}), \\ \text{score memory} &= \Theta(hqmn(mn + d^2)), \\ \text{mask/edge list 构造} &= \Theta(qmnd^2) \text{ 若旋转映射 } O(1). \end{aligned}$

当 mn 和 d 固定时，上式对 q 以及总 token 数 T 都是线性的。

参考说明。本文使用的 zig-zag product 计数规则是： G 为 Δ -正则、 H 为 d -正则且 $|V(H)| = \Delta$ 时， $G \circledast H$ 的顶点数为 $|V(G)|\Delta$ 、度数为 d^2 ；若旋转映射可快速计算，整图输出规模为 $O(d^2|V(G)|\Delta)$ 。这与用户提供的 expander/zig-zag 总结中的定义和复杂度一致。